

НИЯУ МИФИ · Институт интеллектуальных кибернетических систем

Кафедра «Машинное обучение»

Построение и применение композитных векторных представлений текста для многоклассовой классификации текстов

Выпускная квалификационная работа магистра

Направление 01.04.02 «Прикладная математика и информатика». Программа: Машинное обучение

Студент: **Пападык Всеволод Дмитриевич**

Научный руководитель: **Золотарев Александр Маркович**

Москва · 15 июня 2026

Актуальность темы и проблематика

01

Корпоративный документооборот

Общая электронная почта, но разные ответственные за письма. Маршрутизация писем по подразделениям — рутинная задача, которая становится узким местом и блокирует работу.

02

Специфика деловой переписки

Длинные тексты на русском, типовые деловые обороты, аббревиатуры, сильный дисбаланс по подразделениям. Длина писем превышает 512 BERT-токенов.

03

Отсутствие доменной адаптации

Предобученные модели классификации не учитывают терминологию компании и зоны ответственности подразделений. Нужна узкоспециализированная настройка.

Цель и задачи работы

Цель

Разработать и исследовать пайплайн многоклассовой классификации длинных русскоязычных деловых писем на основе классических, эмбединговых и композитных представлений текста.

Задачи

- 1 **Проанализировать** данные, оценить распределение классов, длину текстов, дубликаты
- 2 **Реализовать** TF-IDF baseline и BERT-подходы (ruBERT, ruRoberta-large, чанкинг, Sentence-BERT)
- 3 **Построить** композитные представления TF-IDF + BERT с дообученным эмбеддером
- 4 **Разработать** пайплайн предобработки данных, аугментации, обучения всех моделей классификации
- 5 **Сравнить** подходы по макро F1 и balanced accuracy на фиксированном датасете (готовиться объяснить почему выбраны эти метрики)

Постановка задачи и характеристика данных

Формальная постановка

Дано: множество писем $D = \{d_i\}$, метки $y_i \in \{1, \dots, K\}$, $K = 36$.

Найти: классификатор $f: D \rightarrow \{1, \dots, K\}$, максимизирующий balanced accuracy и macro F1 на отложенной выборке.


Ограничения: фиксированное train/test-разбиение; тестовые тексты не участвуют ни в обучении, ни в аугментации.

Характеристики датасета

Тип	корпоративные письма
Язык	русский
Классов	36 подразделений
Дисбаланс	от единиц до сотен документов в классе
Длина	до десятков тысяч токенов — превышает 512 BERT-токенов
Метрики	balanced accuracy, macro F1

Архитектура пайплайна обработки

Модульный пайплайн: каждый этап изолирован и заменяем. После аугментации — параллельные ветки обучения.



Предобработка и аугментация

Задача: подготовить чистые, сбалансированные данные для обучения, не «протекая» в тест.

Очистка и нормализация

- удаление HTML, подписей, дубликатов
- нормализация регистра и пунктуации
- устранение пересечений train/test

Train/test

Зафиксированное разбиение. Тестовые тексты не используются ни при обучении, ни при аугментации, ни при дообучении эмбеддера.

Текстовая аугментация (только train)

Перефразирование — нейросетевое переписывание формулировок для редких классов через ruT5-large-paraphraser.

Обратный перевод — ru → en/es/fr → ru через OPUS-MT; сохраняет смысл, меняет лексику.

Цель — увеличить вариативность редких классов и выровнять распределение.

Общее увеличение — с 1404 до 2158 документов.

Суммаризация

Задача: проверить, помогает ли сжатие текста до главной мысли, и подготовить альтернативные обучающие выборки.

Подход

- модель `rut5_base_sum_gazeta` (T5, дообучена на корпусе «Газета.Ru»)
- beam search; вход до 600 токенов, выжимка 30–128 токенов
- две версии датасета: замена текста на `summary` и конкатенация `original ⊕ summary`
- обе версии подаются как train в TF-IDF, BERT-классификатор и эмбединги

Вывод: короткая выжимка теряет специфическую лексику деловых писем — длинный контекст важен.

Лучшие результаты

balanced accuracy / macro F1

0.482 / 0.497

BASELINE на `original + summary`

0.512 / 0.498

BERT классификация, `aug + summary`

Замена текста на `summary` ухудшает все модели; связка `original ⊕ summary` почти догоняет.

TF-IDF baseline

Задача: построить сильную базовую линию на классических признаках.

Подход

- word- и char-n-граммы (объединённое признаковое пространство)
- линейные модели: LinearSVC, LogisticRegression, RidgeClassifier
- class_weight=balanced для компенсации дисбаланса
- эталон — TF-IDF + линейные классификаторы для деловых текстов
- просадка метрик на аугментированном наборе объясняется тем, что train модель чаще предсказывала популярные классы, а на аугментации предсказания размазаны, ведь примеров на 754 документа больше

train.csv / train_augmented.csv

0.534 / 0.489

balanced accuracy

0.543 / 0.486

macro F1 (LinearSVC, n-граммы)

TF-IDF + линейные модели остаются конкурентоспособной базовой линией.

BERT с классификационной головой

Задача: оценить плотные контекстные представления и доменную адаптацию.

Реализованные подходы

Базовые модели ruBERT и ruRoberta-large с классификационной головой:

1. классическая на токене CLS
2. mean-pooling по скрытым состояниям
3. chunkmean для длинных документов: текст режется на чанки с перекрытием, эмбединги внутри чанка усредняются, потом усредняются между чанками

train.csv / train_augmented.csv

0.454 / 0.501

balanced accuracy

0.443 / 0.504

macro

*Аугментация помогла BERT-классификатору.
Лучший результат на ruRoberta-large с chunkmean-
головой и аугментацией*

cosine similarity на эмбедингах Sentence-BERT

Задача: оценить плотные контекстные представления и доменную адаптацию.

Реализованные подходы

- sentence-BERT для извлечения эмбедингов: база ruRoberta-large, контрастивный лосс MultipleNegativesRankingLoss
- доменная адаптация эмбеддера на train
- cosine-centroid(робастный): классификация по близости к центроиду класса
- cosine-nearest(soft-vote): top-k ближайших
- centroid+nearest ensemble: взвешенная сумма двух выше

Ключевой результат

0.578

balanced accuracy — абсолютный максимум работы


Cosine-Centroid на дообученных эмбедингах

Эмбединги BERT «из коробки» дают < 0.2 balanced accuracy и macro F1.

После доменной адаптации > 0.5 balanced accuracy и macro F1.

Композитные представления TF-IDF $\oplus$ BERT

Задача: объединить лексические и контекстные признаки и оценить эффект.



MLP на hybrid (custom)

0.543

macro F1 — абсолютный максимум работы

Композитное пространство + дообученный эмбеддер дают лучший общий баланс точности и полноты.

LinearSVC на hybrid (custom)

0.541

macro F1 — почти максимум, при простоте линейной модели

Минимальный разрыв с MLP: при сильных признаках сложный классификатор почти не нужен.

Сводное сравнение подходов на открытых данных

Лучшие конфигурации по каждому подходу; пары — без аугментации / с аугментацией

Подход	Представление	Алгоритм	BAcc	Macro F1
Baseline TF-IDF	TF-IDF (word+char)	LinearSVC	0.534 / 0.489	0.543 / 0.486
BERT-классификация	BERT custom	chunk-mean head	0.454 / 0.501	0.443 / 0.504
Cosine similarity	BERT custom	Centroid (soft)	0.578 / 0.476	0.508 / 0.470
Линейная на гибриде	TF-IDF (word+char) $\oplus$ BERT	LinearSVC	0.526 / 0.446	0.541 / 0.463
MLP на гибриде	TF-IDF (word+char) $\oplus$ BERT	StrongMLP	0.498 / 0.413	0.545 / 0.463

Вывод: на открытых данных лидеры разные: **BAcc** — Cosine similarity на дообученном BERT (0.578), **Macro F1** — MLP на композите TF-IDF $\oplus$ BERT (0.545). Аугментация на этом датасете не даёт выигрыша — выборка уже сбалансирована.

Сводное сравнение подходов на закрытых данных

Лучшие конфигурации по каждому подходу; пары — без аугментации / с аугментацией

Подход	Представление	Алгоритм	BAcc	Macro F1
Baseline TF-IDF	TF-IDF (word+char)	LinearSVC	0.604 / 0.579	0.611 / 0.582
BERT-классификация	BERT custom	chunk-mean head	0.474 / 0.572	0.490 / 0.595
Cosine similarity	BERT custom	Centroid (soft)	0.548 / 0.584	0.516 / 0.610
Линейная на гибриде	TF-IDF (word+char) $\oplus$ BERT	RidgeClassifier	0.568 / 0.597	0.588 / 0.623
MLP на гибриде	TF-IDF (word+char) $\oplus$ BERT	StrongMLP	0.608 / 0.599	0.622 / 0.625

Вывод: на закрытых данных аугментация даёт прирост у плотных методов (BERT-head +0.10 F1, Cosine +0.09 F1, гибрид +0.03 F1). **Главный результат работы:** композитный вектор TF-IDF $\oplus$ BERT с StrongMLP и аугментацией — BAcc 0.608 / F1 0.625, лучшие по обоим метрикам, +0.029 BAcc и +0.043 F1 к фиксированному baseline.

Выводы. Цель достигнута

Цель достигнута: разработан воспроизводимый пайплайн классификации длинных русскоязычных деловых писем; реализованы и сравнены TF-IDF, BERT и композитные представления; получены метрики на единой выборке.

1

Сила признаков важнее сложности модели

на сильных признаках LinearSVC почти не уступает MLP

2

Доменная адаптация — ключ к BERT

без неё BERT-эмбединги уступают TF-IDF на узкодоменной задаче

3

Композит даёт лучший macro F1

TF-IDF $\oplus$ custom BERT — 0.625 F1 (MLP, с aug), абсолютный максимум работы

4

Аугментация не универсальна

На закрытых данных аугментация даёт прирост F1: BERT-head +0.10, Cosine +0.09, гибрид +0.03. TF-IDF от aug не выигрывает.

Практическая значимость и перспективы

Практическая значимость

- Модульный прототип пайплайна классификации
- Применим для маршрутизации корпоративных писем
- Адаптируемость к новому домену: дообучение эмбеддера и пересборка TF-IDF на корпусе заказчика

Перспективы развития

- более мощные модели для длинных документов (Longformer)
- обучаемые механизмы объединения TF-IDF и BERT

Репозиторий с кодом



github.com/sevaTechoPark/mifi-vkr

весь код, данные и логи экспериментов