

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ
«МИФИ»

ИНСТИТУТ ИНТЕЛЛЕКТУАЛЬНЫХ КИБЕНЕТИЧЕСИКХ СИСТЕМ

КАФЕДРА «МАШИННОЕ ОБУЧЕНИЕ»

На правах рукописи

УДК _____

Пападык Всеволод Дмитриевич

**«Построение и применение композитных векторных представлений
текста для многоклассовой классификации текстов»**

Выпускная квалификационная работа магистра

Направление подготовки 01.04.02
«Прикладная математика и информатика»

Выпускная
квалификационная работа
защищена
«__»_____ 2026
г.
Оценка

Секретарь ГЭК

г. Москва
2026

РЕФЕРАТ

КОМПОЗИТНЫЕ ВЕКТОРНЫЕ ПРЕДСТАВЛЕНИЯ, МНОГОКЛАССОВАЯ КЛАССИФИКАЦИЯ ТЕКСТОВ, АУГМЕНТАЦИЯ ДАННЫХ, TF-IDF, RUBERT

Объектом исследования являются методы автоматической многоклассовой классификации текстов в условиях ограниченного и несбалансированного корпоративного датасета.

Целью работы является исследование и реализация различных методов построения векторных представлений текста, включая подготовку к использованию композитных эмбедингов, и оценка их влияния на качество многоклассовой классификации с учётом совместной предобработки и аугментации данных.

В процессе работы проведён разведочный анализ исходных данных, выявлены структура и дисбаланс классов, разработаны и реализованы процедуры предобработки и очистки текстов. Реализованы два сценария текстовой аугментации для малочисленных классов: перефразирование и обратный перевод, позволяющие выровнять распределение классов и увеличить вариативность формулировок.

Построены и исследованы модели классификации на основе классического пайплайна TF-IDF + LinearSVC и нейросетевой модели ruBERT, обученные на исходном и аугментированных наборах данных. Выполнено сравнение моделей по набору метрик (accuracy, balanced accuracy, макро- и взвешенная F1-мера), а также проведён анализ ошибок и трудных классов. На основе полученных результатов сформулированы подходы к дальнейшему построению композитных векторных представлений текстов для улучшения качества классификации.

Основные характеристики разработанного прототипа включают модульную архитектуру пайплайна (предобработка, аугментация, построение эмбедингов, обучение и оценка моделей), возможность сравнения классических и нейросетевых подходов и готовность к расширению за счёт внедрения композитных эмбедингов.

Степень внедрения результатов работы определяется возможностью адаптации разработанного прототипа к задачам автоматической классификации корпоративных текстов, в частности маршрутизации обращений и категоризации внутренних документов. Полученные наработки и программная реализация могут быть использованы в качестве основы для последующей интеграции в промышленные системы анализа текстовых данных.

Ключевые слова: МНОГОКЛАССОВАЯ КЛАССИФИКАЦИЯ, ТЕКСТОВЫЕ ЭМБЕДДИНГИ, КОМПОЗИТНЫЕ ПРЕДСТАВЛЕНИЯ, АУГМЕНТАЦИЯ ТЕКСТОВ, TF-IDF, RUBERT, НЕЙРОСЕТЕВЫЕ МОДЕЛИ.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	6
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	8
ВВЕДЕНИЕ	9
1 Обзор предметной области	11
1.1 Многоклассовая классификация текстов и её приложения.....	11
1.2 Особенности классификации длинных русскоязычных деловых писем	11
1.3 Векторные представления текста: от Bag-of-Words до контекстных эмбеддингов	12
1.4 Проблемы разреженности, дисбаланса классов и качества текстовых представлений	12
1.5 Методы аугментации текстовых данных	13
1.6 Подходы к обработке длинных текстов в transformer-моделях	14
1.7 Идея композитных векторных представлений текста	15
2 Разведочный анализ и предобработка данных	16
2.1 Структура датасета и распределение классов.....	16
2.2 Анализ длины текстов и качества исходных данных.....	17
2.3 Обнаружение дубликатов, пересечений и аномальных объектов.....	18
2.4 Правила очистки и нормализации текстов.....	19
2.5 Итоговое состояние данных после предобработки	19
2.6 Особенности train/test-разбиения и распределения классов.....	20
3 Постановка задачи и проектирование решения.....	23
3.1 Формальная постановка задачи многоклассовой классификации	23
3.2 Требования к разрабатываемому решению.....	23
3.3 Влияние предметной области на проектирование решения.....	23
3.4 Общая архитектура пайплайна обработки и классификации текста	23
3.5 Выбор направлений моделирования	25
3.6 Использование суммаризации для подготовки дополнительных представлений текста.....	25
3.7 Построение суммаризованного и комбинированного наборов данных	26
3.8 Выбор метрик качества классификации	26
4 Аугментация данных и обогащение выборки.....	27
4.1 Мотивация аугментации при дисбалансе классов.....	27
4.2 Аугментация классическими методами без использования нейросетевых моделей	27
4.3 Общая схема нейросетевой аугментации длинных текстов	27
4.4 Разбиение текста на предложения и фрагменты при аугментации	27
4.5 Генерация нескольких вариантов аугментации и выбор итогового кандидата.....	28
4.6 Схема доведения редких классов до порогового размера выборки.....	28
4.7 Аугментация с использованием перефразирования.....	29

4.8	Аугментация методом обратного перевода	29
4.9	Фильтрация аугментированных текстов по косинусному сходству.....	30
4.10	Склейка аугментированных фрагментов в полный текст документа.....	30
4.11	Формирование итогового аугментированного набора данных	30
4.12	Анализ распределения данных после аугментации	31
5	Классические модели на основе разреженных текстовых признаков.....	33
5.1	Теоретические основы TF-IDF-представления текста	33
5.2	Линейные классификаторы для разреженных текстовых признаков	33
5.3	Построение признаков на основе word n-грамм	34
5.4	Построение признаков на основе символьных char n-грамм	34
5.5	Комбинирование word- и char-признаков в едином признаковом пространстве	34
5.6	Реализация пайплайна TF-IDF + LinearSVC	35
5.7	Реализация пайплайна TF-IDF + LogisticRegression	35
5.8	Дополнительные классические модели классификации.....	35
5.9	Особенности применения TF-IDF к длинным деловым письмам.....	36
6	Контекстные представления и классификация на основе BERT-моделей	37
6.1	Теоретические основы transformer-архитектур.....	37
6.2	Контекстные эмбединги и их отличие от разреженных признаков.....	37
6.3	Используемые русскоязычные модели ruBERT и ruRoberta-large.....	37
6.4	Два подхода к использованию BERT в задаче классификации	37
6.4.1	Дообучение BERT/Sentence-BERT для построения эмбедингов	37
6.4.2	Дообучение BERT как end-to-end классификатора	37
6.5	Классификация текстов с использованием выхода AutoModel.....	37
6.6	Классификация текстов с использованием mean pooling	37
6.7	Построение Sentence-BERT-представлений документов	37
6.8	Эксперименты с ruBERT-base-cased и различными классификационными головами	37
6.9	Эксперименты с ruRoberta-large и различными классификационными головами	37
6.10	Ограничение длины входной последовательности и проблема длинных документов	38
6.11	Разбиение длинных текстов на перекрывающиеся чанки	38
6.12	Агрегация представлений чанков на уровне документа.....	38
6.13	Архитектура основного классификатора для чанкированных документов.....	38
6.14	Параметры обучения ruRoberta-large с чанкингом.....	38
6.15	Регуляризация и стабилизация обучения на малой выборке	38
7	Композитные и эмбединговые представления текста	39
7.1	Построение BERT-эмбедингов документов.....	39
7.2	Использование эмбедингов предобученной модели	39
7.3	Использование эмбедингов дообученной модели.....	39

7.4 Классические классификаторы поверх плотных эмбедингов	39
7.5 Классификация по центроидам классов	39
7.6 Классификация методом ближайшего соседа.....	39
7.7 Конкатенация TF-IDF и BERT-векторов	39
7.8 Реализация композитного признакового пространства	39
7.9 Использование классических моделей и MLP-классификатора поверх композитных векторов	39
8 Программная реализация разработанного пайплайна	40
8.1 Общая структура программного решения.....	40
8.2 Модуль предобработки данных.....	40
8.3 Модуль аугментации текстов	40
8.4 Модуль построения векторных представлений	40
8.5 Модуль обучения моделей.....	40
8.6 Воспроизводимость экспериментов.....	40
8.7 Ограничения реализации и требования к вычислительным ресурсам	40
9 Экспериментальное исследование и сравнение результатов	41
9.1 Экспериментальный протокол оценки качества.....	41
9.2 Используемые метрики качества классификации	41
9.3 Сравнение качества на исходной и аугментированной обучающей выборке	41
9.4 Сравнение исходных, суммаризованных и комбинированных текстовых представлений	41
9.5 Сводная таблица результатов всех реализованных подходов.....	41
9.6 Анализ влияния аугментации на качество классификации	41
9.7 Сравнение классических, нейросетевых и композитных представлений	41
9.8 Выводы по результатам экспериментального исследования	41
ЗАКЛЮЧЕНИЕ.....	42
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	44

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчете применяют следующие термины с соответствующими определениями:

Многоклассовая классификация текста	— процесс отнесения текстового объекта к одному из заранее определённых классов из конечного множества категорий
Векторное представление текста (эмбединг текста)	— численное представление текста в виде вектора фиксированной длины, формируемое таким образом, чтобы сохранять семантические и синтаксические свойства исходного текста
Композитное векторное представление текста	— векторное представление, полученное путём объединения двух и более базовых эмбедингов, построенных различными методами (например, TF-IDF и контекстные эмбединги), для более полного отражения свойств текста
Текстовая аугментация	— совокупность методов искусственного увеличения объёма обучающей выборки за счёт генерации новых текстов на основе исходных с сохранением их семантики (перифразирование, обратный перевод и другие методы)
Перифразирование текста	— метод текстовой аугментации, при котором исходный текст преобразуется в новый текст, близкий по смыслу, но отличающийся лексически и/или синтаксически
Обратный перевод (back-translation)	— метод текстовой аугментации, при котором исходный текст переводится на другой язык, а затем обратно, в результате чего получается новый текст, сохраняющий исходный смысл при изменённой формулировке
Базовая модель классификации	— модель, реализующая простой или широко используемый подход (например, TF-IDF + линейный классификатор), служащая отправной точкой для сравнения с более сложными решениями
Нейросетевая модель классификации текста	— модель классификации, основанная на искусственных нейронных сетях (в том числе трансформерных архитектурах), использующая распределённые векторные представления текста

Корпоративный
датасет текстов

— набор текстовых данных,
сформированный в рамках деятельности
организации и отражающий её реальные
процессы (обращения, документы, описания
инцидентов и т.п.)

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчете применяют следующие сокращения и обозначения:

BERT	—	Bidirectional Encoder Representations from Transformers, двунаправленная языковая модель на основе архитектуры трансформеров
ruBERT	—	русскоязычная модификация модели BERT, предобученная на русскоязычных текстовых коллекциях
TF-IDF	—	Term Frequency – Inverse Document Frequency, взвешенная частотная модель представления текста, учитывающая частоту термина в документе и редкость термина в коллекции
SVM	—	Support Vector Machine, метод опорных векторов, класс алгоритмов машинного обучения для решения задач классификации и регрессии
F1-мера (F1)	—	гармоническое среднее между точностью (precision) и полнотой (recall), используемое для оценки качества классификации
Balanced F1(macro-F1)	—	сбалансированная F1-мера при мультиклассовой классификации: вычисляется F1-мера отдельно для каждого класса и затем берётся их среднее арифметическое, так что все классы учитываются равноправно, независимо от дисбаланса по количеству объектов
Accuracy	—	доля правильно классифицированных объектов в общей выборке
Balanced accuracy	—	сбалансированная точность, среднее арифметическое по классам от доли правильно классифицированных объектов каждого класса
GPU	—	Graphics Processing Unit, графический процессор, используемый для ускорения вычислений при обучении нейросетевых моделей
EDA	—	Exploratory Data Analysis, первичный исследовательский анализ данных

ВВЕДЕНИЕ

В условиях стремительного роста объёмов текстовой информации задачи автоматической классификации документов и сообщений становятся ключевыми для современных информационных систем. Они лежат в основе тематической маршрутизации обращений, аналитики пользовательской активности, мониторинга инцидентов и поддержки принятия управленческих решений. При этом на практике такие задачи часто имеют многоклассовый характер и сопровождаются выраженным дисбалансом классов, что существенно осложняет построение надёжных и устойчивых моделей.

Традиционные подходы к представлению текста, основанные на мешке слов и TF-IDF, позволяют эффективно использовать линейные классификаторы, но имеют ряд ограничений. Они плохо учитывают семантическую близость слов и чувствительны к вариативности формулировок, что приводит к потере части смысловой информации. Появление распределённых векторных представлений, а затем и контекстных эмбедингов на основе трансформеров (таких как BERT), существенно повысило качество решения задач обработки естественного языка. Однако даже в этих условиях итоговая эффективность классификации в значительной степени определяется тем, насколько удачно выбраны и скомбинированы представления текста, а также тем, как учтён дисбаланс и ограниченность данных.

Особый интерес представляет подход, при котором для одного и того же текста формируются несколько векторных представлений, полученных различными методами, а затем объединяются в композитный эмбединг. Такой подход позволяет использовать сильные стороны каждого из базовых представлений: устойчивость TF-IDF к редким словам и артефактам, способность контекстных моделей учитывать окружение слова, а также дополнительные признаки, отражающие структуру и формальные особенности текста. В сочетании с целевой аугментацией данных для редких классов это открывает возможности для улучшения качества многоклассовой классификации без радикального увеличения объёма исходной обучающей выборки.

Настоящая работа посвящена исследованию методов построения и применения композитных векторных представлений текста для задач многоклассовой классификации на примере реального корпоративного датасета с выраженным дисбалансом классов. В рамках работы проводится разведочный анализ данных, реализуются сценарии текстовой аугментации (перефразирование и обратный перевод), строятся базовые и нейросетевые модели классификации, а также закладывается основа для формирования сложных эмбедингов на основе комбинирования различных представлений.

Цель работы заключается в исследовании и реализации методов построения векторных представлений текста, в том числе композитных эмбедингов, и оценке их влияния на качество многоклассовой классификации с учётом совместной предобработки и аугментации данных.

Для достижения поставленной цели в работе решаются следующие задачи:

- 1) провести разведочный анализ исходного датасета, оценить структуру и дисбаланс классов, а также качество текстов;
- 2) разработать и реализовать процедуры предобработки и очистки текстов, учитывающие специфику предметной области;
- 3) исследовать и реализовать методы текстовой аугментации (перефразирование и обратный перевод) для обогащения малочисленных классов;
- 4) построить базовый классический пайплайн классификации на основе TF-IDF и линейного классификатора и оценить его качество;
- 5) реализовать и обучить нейросетевую модель на основе ruBERT для многоклассовой классификации текстов;
- 6) сравнить качество моделей на исходном и аугментированных наборах данных, проанализировать влияние аугментации на редкие классы;
- 7) сформулировать требования и подходы к построению композитных векторных представлений текста для дальнейших экспериментов.

Объектом исследования в работе является процесс автоматической многоклассовой классификации текстов в условиях ограниченного и несбалансированного датасета.

Предметом исследования являются методы построения векторных представлений текста и подходы к их комбинированию в композитные эмбединги, а также их влияние на качество классификации при использовании классических и нейросетевых моделей.

Теоретическая значимость работы состоит в систематизации и уточнении представлений о влиянии разных типов векторных представлений и приёмов аугментации на качество многоклассовой текстовой классификации. Рассматривается связка: предобработка, аугментация, выбор модели и стратегия формирования эмбедингов, что позволяет уточнить роли каждого компонента в общей архитектуре решения.

Практическая значимость работы выражается в разработке воспроизводимого программного прототипа, включающего полный пайплайн обработки данных: от предобработки и аугментации до обучения и оценки моделей классификации. Полученные результаты и рекомендации могут быть использованы при разработке систем маршрутизации обращений, автоматической категоризации внутренних документов и других прикладных задач анализа текстовых данных в корпоративной среде

1 Обзор предметной области

1.1 Многоклассовая классификация текстов и её приложения

Многоклассовая классификация текстов — это задача автоматического отнесения документа к одной из нескольких заранее заданных категорий. Такая задача возникает в тех случаях, когда текстовый поток необходимо распределить по конкретным темам.

На практике многоклассовая классификация используется в системах электронного документооборота, службах поддержки, корпоративных почтовых системах, новостных агрегаторах, юридических и финансовых информационных системах. Например, входящее письмо может быть автоматически отнесено к определённому проекту, отделу, типу запроса или зоне ответственности сотрудника. Это позволяет сократить ручную обработку документов.

В рамках данной работы рассматривается прикладной вариант этой задачи: классификация длинных русскоязычных деловых писем по 36 классам. Документы имеют значительную длину, содержат формальные обороты, подписи, пересылаемые фрагменты, служебные конструкции и предметно-специфичную лексику. Кроме того, отдельные классы могут быть близки по смыслу, так как относятся к смежным подразделениям, проектам или направлениям деятельности. Поэтому модель должна учитывать не только отдельные ключевые слова, но и общий контекст письма.

Дополнительную сложность создаёт ограниченный и несбалансированный набор данных. В исходной обучающей выборке разные классы представлены неравномерно: одни категории содержат большое количество писем, а другие имеют только несколько примеров. В такой ситуации модель может смещаться в сторону крупных классов и хуже распознавать редкие категории. Поэтому в работе задача классификации рассматривается совместно с анализом распределения классов, предобработкой текстов, аугментацией данных и сравнением разных способов построения текстовых представлений.

1.2 Особенности классификации длинных русскоязычных деловых писем

В деловой переписке текст часто строится по более сложной структуре: в одном письме могут присутствовать приветствие, описание ситуации, ссылки на предыдущие договорённости, пересылаемые фрагменты, подписи, реквизиты, уточнения по срокам и исполнителям. При этом не все части письма одинаково полезны для определения класса. Например, подписи и служебные блоки могут повторяться в разных категориях, а ключевая информация может находиться только в одном или нескольких абзацах.

В рассматриваемой задаче документы являются длинными русскоязычными деловыми письмами. Это накладывает несколько ограничений на выбор методов обработки текста. Во-первых, длинные документы сложнее подавать на вход transformer-моделям, так как большинство BERT-подобных архитектур имеет ограничение на длину входной последовательности. Если просто обрезать письмо до фиксированного числа токенов, часть значимой информации может быть потеряна. Во-вторых, длинный текст часто содержит информационный шум: повторяющиеся служебные конструкции, фрагменты переписки, стандартные формулировки и элементы, которые не помогают отличать один класс от другого.

Русский язык дополнительно усложняет задачу за счёт развитой морфологии и свободного порядка слов. Одни и те же сущности, действия и признаки могут встречаться в разных грамматических формах. Для классических моделей это означает увеличение числа возможных токенов и разреженность признакового пространства. Для нейросетевых моделей проблема проявляется иначе: модель может лучше учитывать контекст, но при

малом количестве размеченных примеров не всегда получает достаточно данных для устойчивого дообучения под конкретную предметную область.

Специфика деловой переписки также связана с высокой тематической близостью классов. В отличие от задач, где категории хорошо различимы по лексике, в корпоративных письмах разные классы могут использовать сходные термины, шаблоны и управленческие формулировки. Например, письма, относящиеся к разным подразделениям или проектам, могут содержать одинаковые слова о согласовании, сроках, документах, исполнителях и отчётности. Поэтому классификатору необходимо выделять не только общеделовую лексику, но и более тонкие признаки, связанные с конкретным направлением или контекстом письма.

1.3 Векторные представления текста: от Bag-of-Words до контекстных эмбеддингов

Для применения алгоритмов машинного обучения текст должен быть преобразован в численное представление — вектор признаков фиксированной длины. Самые ранние подходы опирались на модели one-hot и Bag-of-Words, в которых каждый текст описывается вектором, отражающим частоты или наличие слов из словаря. Расширение этой идеи — TF-IDF — позволяет взвешивать слова с учётом их частоты в документе и редкости в коллекции, снижая влияние часто встречающихся, но малоинформативных терминов.

Однако такие представления не учитывают порядок слов и семантическую близость, а также страдают от разреженности при больших словарях. Для преодоления этих ограничений были предложены плотные распределённые представления слов (word embeddings), получаемые, например, методами Word2Vec, GloVe и FastText, в которых каждая лексема отображается в вектор невысокой размерности, обученный на больших корпусах. Последующим шагом стало появление контекстных эмбеддингов, в том числе на основе архитектуры BERT, которые формируют представление токена или целого текста с учётом контекста, что позволяет различать многозначные слова и тонкие смысловые нюансы.

Поскольку разные типы представлений фиксируют разные свойства текста, в работе также рассматривается идея композитного признакового пространства. В таком подходе разреженные TF-IDF-признаки объединяются с плотными BERT-векторами, после чего поверх общего представления обучается классификатор. Цель такого подхода заключается в том, чтобы совместить сильные стороны классических и нейросетевых представлений: чувствительность TF-IDF к характерным словам и фразам, а также способность BERT-моделей учитывать контекст и семантическую близость текстов.

Из-за перечисленных особенностей в работе рассматривается несколько способов представления и обработки текстов. Для классического подхода используются TF-IDF-признаки, включая word- и char-ngram-представления, так как они позволяют учитывать как отдельные слова, так и устойчивые фрагменты словоформ. Для нейросетевых моделей исследуются BERT-модели, которые способны строить контекстные представления текста. Отдельно рассматриваются композитные представления, объединяющие разные типы признаков.

1.4 Проблемы разреженности, дисбаланса классов и качества текстовых представлений

При классификации текстов качество модели во многом зависит от того, насколько удачно исходные документы преобразованы в признаковое пространство. В классических подходах, таких как Bag-of-Words и TF-IDF, каждый документ описывается большим количеством признаков, соответствующих словам, n-граммам или символьным

фрагментам. Такое пространство обычно получается высокоразмерным и разреженным: большая часть признаков для конкретного документа имеет нулевые значения. Это естественно для текстовых данных, так как даже длинное письмо содержит только малую часть всех возможных слов и сочетаний, встречающихся в корпусе.

Разреженность сама по себе не делает метод непригодным. Линейные модели часто хорошо работают с такими признаками, поскольку могут выделять информативные слова и устойчивые выражения для каждого класса. Однако при малом количестве обучающих примеров возникают ограничения. Если редкий класс представлен несколькими письмами, модель видит слишком мало вариантов формулировок и может переобучиться на случайные слова, подписи, имена проектов или служебные фрагменты. В результате признаки, которые не отражают сущность класса, могут получить слишком большой вес.

В рассматриваемой задаче эта проблема усиливается дисбалансом классов. Исходная обучающая выборка содержит 36 классов, но количество документов по ним распределено неравномерно: для части классов доступно большое число примеров, а отдельные категории представлены единичными письмами. В такой ситуации модель может показывать приемлемое общее качество за счёт крупных классов, но плохо распознавать малые классы. Поэтому при анализе результатов важно использовать не только общую долю правильных ответов, но и метрики, чувствительные к качеству на каждом классе, например *balanced accuracy* и *macro F1*.

Дисбаланс влияет не только на классические модели, но и на нейросетевые подходы. BERT-подобные модели обладают более выразительными представлениями, однако для дообучения под конкретную предметную область им также требуется достаточное количество размеченных примеров. Если данных мало, а классы близки по тематике, модель может не получить устойчивого сигнала для разделения категорий. Особенно это заметно в задачах с длинными документами, где значимая информация может занимать небольшую часть текста, а остальное содержимое создаёт шум.

Качество текстового представления также зависит от того, какие уровни информации оно учитывает. Словные признаки хорошо отражают явные термины и фразы, но чувствительны к вариативности формулировок. Символьные *n*-граммы помогают работать с морфологией, сокращениями и частичными совпадениями слов. Контекстные эмбединги лучше учитывают смысловые связи, но могут терять часть информации при ограничении длины входа или при недостаточном объёме обучающих данных. Поэтому в данной работе рассматриваются несколько типов представлений: разреженные TF-IDF-признаки, плотные BERT-эмбединги, а также композитные векторы, объединяющие разные источники информации.

Для уменьшения влияния дисбаланса и повышения разнообразия обучающих примеров в работе используется аугментация данных. Она применяется только к обучающей выборке и направлена на расширение представления редких классов за счёт перефразирования и обратного перевода. Дополнительно рассматриваются суммаризованные и комбинированные варианты данных, позволяющие проверить, может ли сжатое представление документа сохранить признаки, важные для классификации. Таким образом, проблемы разреженности, дисбаланса и качества признаков определяют не только выбор моделей, но и общую структуру экспериментального пайплайна.

1.5 Методы аугментации текстовых данных

Аугментация текстовых данных применяется в тех случаях, когда исходная обучающая выборка недостаточна по объёму или имеет выраженный дисбаланс между классами. Основная идея заключается в создании дополнительных обучающих примеров на основе уже размеченных текстов. При этом новые тексты должны сохранять исходную метку класса, но отличаться по формулировкам, структуре или отдельным языковым

признакам. Для задачи классификации это позволяет увеличить разнообразие обучающих примеров и снизить зависимость модели от случайных фрагментов исходных документов.

В текстовых задачах аугментация сложнее, чем в изображениях или табличных данных. Небольшое изменение слова может изменить смысл документа, нарушить стиль или сделать текст неестественным. Поэтому для классификации деловых писем важно не просто создать дополнительные варианты текста, а сохранить его основное содержание и принадлежность к тому же классу. Особенно это критично для редких классов, где каждый исходный пример оказывает заметное влияние на обучение модели.

Существуют простые методы аугментации без использования нейросетевых моделей. К ним относятся замена слов синонимами, случайное удаление или перестановка слов, вставка близких по смыслу слов, небольшие изменения пунктуации. Такие методы легко реализуются и не требуют больших вычислительных ресурсов, однако для длинных деловых писем они имеют ограниченную применимость. В подобных документах важны формулировки, терминология и деловой стиль, поэтому случайные изменения могут создавать шум и ухудшать качество обучающих данных.

Более содержательными являются методы нейросетевой аугментации. В данной работе рассматриваются два таких подхода: перефразирование и обратный перевод. Перефразирование направлено на получение нового варианта текста с сохранением исходного смысла. Обратный перевод строится иначе: текст переводится на промежуточный язык, а затем обратно на русский. В результате часть формулировок изменяется, но общий смысл документа должен сохраняться. Оба метода позволяют получить более естественные варианты текста по сравнению с простыми случайными заменами.

Для длинных писем аугментация полного текста целиком может быть затруднена из-за ограничений моделей и высокой длины входной последовательности. Поэтому в работе используется обработка на уровне фрагментов: документ разбивается на предложения и более короткие части, для которых генерируются варианты аугментации. После этого фрагменты объединяются обратно в полный текст. Такой подход позволяет применять модели аугментации к длинным документам и при этом сохранять общую структуру письма.

Важным этапом является контроль качества сгенерированных текстов. Если аугментированный пример слишком близок к исходному, он почти не добавляет новой информации для обучения. Если же он слишком сильно отличается, возникает риск изменить смысл и получить пример с некорректной меткой. Поэтому в работе используется фильтрация по косинусному сходству между исходным и аугментированным текстом. В итоговую обучающую выборку включаются только те варианты, которые сохраняют достаточную смысловую близость к оригиналу, но не являются его почти точной копией.

1.6 Подходы к обработке длинных текстов в transformer-моделях

При работе с длинными документами Transformer-модели имеют важное ограничение: стандартные BERT-подобные архитектуры принимают на вход последовательность ограниченной длины. На практике это означает, что длинное письмо не всегда может быть обработано целиком. Если документ просто обрезается до максимально допустимой длины, часть информации может быть потеряна, причём заранее неизвестно, где именно находится фрагмент, важный для классификации.

Один из практических способов работы с длинными текстами заключается в разбиении документа на несколько фрагментов. Каждый фрагмент подаётся в transformer-модель отдельно, после чего полученные представления объединяются на уровне документа. Фрагменты могут формироваться с перекрытием, чтобы информация на границах частей не терялась. Такой подход позволяет использовать стандартные BERT-

подобные модели без изменения их архитектуры и при этом учитывать большую часть исходного письма.

В данной работе этот принцип используется при реализации классификатора на основе ruRoberta-large для длинных документов. Текст разбивается на чанки фиксированной длины с заданным шагом, после чего модель обрабатывает несколько фрагментов одного письма. Далее признаки фрагментов агрегируются и передаются в классификационную голову. Такой подход выбран как компромисс между полнотой использования текста и вычислительными ограничениями, поскольку обработка всех возможных фрагментов длинного письма может быть слишком затратной.

Помимо чанкинга, для длинных текстов может применяться суммаризация. В этом случае из исходного документа формируется сокращённая версия, которая должна сохранять основное содержание. Такой вариант полезен для проверки гипотезы о том, достаточно ли краткого представления письма для определения класса. В работе поэтому рассматриваются не только исходные тексты, но и суммаризованные документы, а также комбинированный вариант, где суммаризованный текст используется вместе с оригиналом. Это позволяет сравнить, какую роль играет полный текст и насколько информативным оказывается его сжатое представление.

1.7 Идея композитных векторных представлений текста

Разные способы представления текста фиксируют разные свойства документа. Разреженные признаки, построенные с помощью TF-IDF, хорошо отражают наличие характерных слов, устойчивых словосочетаний и символьных фрагментов. Они особенно полезны в тех случаях, когда класс можно частично определить по специфичной терминологии, названиям проектов, подразделений, типовым формулировкам или повторяющимся деловым оборотам. При этом такие признаки слабо учитывают общий смысл текста и не всегда устойчивы к изменению формулировок.

Контекстные представления, получаемые с помощью BERT-подобных моделей, решают другую задачу. Они позволяют учитывать окружение слов и строить более плотное семантическое описание текста. Благодаря этому близкие по смыслу формулировки могут получать похожие векторы даже при различии в конкретных словах. Для деловой переписки это важно, поскольку один и тот же тип обращения может быть выражен разными фразами. Однако плотные эмбединги не всегда явно сохраняют информацию о редких, но важных токенах, которые могут быть значимыми для конкретного класса.

Идея композитного векторного представления заключается в объединении нескольких источников признаков в одном пространстве. В рамках данной работы это означает конкатенацию разреженного TF-IDF-представления и плотного BERT-вектора. Такое объединение позволяет одновременно использовать лексические признаки и контекстную информацию. TF-IDF-компонента отвечает за точные совпадения слов, n-грамм и символьных шаблонов, а BERT-компонента добавляет информацию о семантике и контексте документа.

После построения композитного вектора задача классификации сводится к обучению модели поверх объединённого признакового пространства. В работе для этого рассматриваются классические классификаторы: LinearSVC и LogisticRegression, а также MLP-классификатор. Такой подход позволяет проверить, может ли объединение разреженных и плотных признаков дать более информативное описание текста по сравнению с использованием каждого типа представления отдельно.

2 Разведочный анализ и предобработка данных

2.1 Структура датасета и распределение классов

В работе используется набор русскоязычных деловых писем, размеченных по тематическим классам. Каждый объект датасета представляет собой отдельный текстовый документ, которому сопоставлена одна целевая метка. Конфиденциальная информация в документах заменена масками-заполнителями. Метка соответствует направлению, проекту, подразделению или иной категории, используемой для классификации письма. Таким образом, задача рассматривается как классификация одного документа в один из заранее заданных классов.

Всего в наборе данных представлено 36 классов. Такое количество категорий делает задачу более сложной по сравнению с бинарной классификацией или классификацией на небольшое число тем. При этом классы не являются равномерными по объёму: часть категорий содержит большое число документов, а некоторые представлены существенно меньшим количеством примеров, распределение представлено на рисунке 2.1. Для реальных деловых данных такая ситуация является естественной, так как интенсивность переписки по разным направлениям может значительно отличаться.



Рисунок 2.1 — Распределение числа текстов по классам

Анализ распределения классов показывает, что датасет имеет выраженный дисбаланс. Наиболее крупные классы содержат существенно больше документов, чем редкие категории. Это означает, что разные классы представлены в обучающих данных с разной степенью полноты: для крупных категорий модель может наблюдать больше вариантов формулировок, а для малых — только ограниченное число примеров. Данная особенность учитывается при выборе метрик качества и при проектировании этапа аугментации.

2.2 Анализ длины текстов и качества исходных данных

В рамках анализа рассматривались базовые характеристики длины документов: количество символов, количество слов и приблизительная длина в токенах. Распределения представлены на рисунках 2.2 и 2.3. Для классических моделей на основе TF-IDF большая длина текста обычно не является техническим ограничением, однако она увеличивает количество потенциальных признаков и может усиливать влияние повторяющихся служебных фрагментов. Для BERT-моделей длина текста является более критичным фактором, так как входная последовательность ограничена фиксированным числом токенов.



Рисунок 2.2 — Распределение длины документов по числу символов



Рисунок 2.3 — Распределение длины документов по числу слов или токенов

Анализ показал, что в наборе данных присутствуют как относительно короткие письма, так и длинные документы. Помимо длины, анализировалось качество исходных данных. В деловой переписке часто встречаются технические элементы, которые не всегда несут полезную информацию для классификации: подписи, приветствия, повторы, служебные символы, ссылки, шаблонные фразы, фрагменты пересланной переписки. Такие элементы могут встречаться в разных классах и создавать шум в признаковом пространстве. При этом полностью удалять все служебные конструкции нельзя, поскольку часть из них может быть связана с конкретным подразделением, проектом или типом документа.

В результате анализа было установлено, что исходный набор данных требует предварительной очистки и нормализации, но при этом содержит достаточно информативные тексты для построения классификационного пайплайна. Основные ограничения связаны с неоднородной длиной документов, наличием служебных фрагментов и потенциальной потерей информации при обработке длинных писем transformer-моделями. Эти факторы были учтены при проектировании этапов предобработки, аугментации, суммаризации и классификации.

2.3 Обнаружение дубликатов, пересечений и аномальных объектов

На этапе подготовки данных была выполнена проверка набора писем на наличие дубликатов, пересечений между выборками и аномальных объектов. Для задачи классификации это является важным этапом, поскольку качество итоговой модели должно оцениваться на документах, которые не использовались при обучении. Если одинаковые или почти одинаковые тексты оказываются одновременно в обучающей и тестовой выборках, итоговые метрики могут быть завышены и не будут отражать реальную способность модели классифицировать новые письма.

В первую очередь были проанализированы точные дубликаты текстов. Под точным дубликатом в данном случае понимается полное совпадение содержимого письма после базовой нормализации. Такие объекты могут появляться из-за повторной загрузки данных, технического объединения нескольких файлов или повторного сохранения одного и того же письма. Наличие точных дубликатов внутри обучающей выборки не всегда приводит к утечке данных, но может усиливать вклад отдельных документов и искажать распределение классов. Поэтому такие случаи необходимо учитывать при дальнейшей обработке.

Кроме дубликатов, анализировались аномальные объекты. К ним относились письма с очень малым количеством содержательного текста, документы с чрезмерно большой длиной, а также тексты, состоящие преимущественно из технических элементов. Такие объекты могут по-разному влиять на модели. Слишком короткие письма содержат мало признаков для классификации, а слишком длинные могут включать пересланные цепочки, подписи, повторяющиеся блоки и служебные строки, которые создают шум.

При обработке аномальных объектов использовался осторожный подход. Полное удаление всех нестандартных фрагментов может привести к потере полезной информации, так как в деловых письмах значимыми могут быть названия подразделений, должности, номера проектов, аббревиатуры и служебные обозначения. Поэтому основной целью являлось не агрессивное сокращение текста, а устранение явно технических проблем и проверка того, что данные пригодны для дальнейшего обучения моделей.

2.4 Правила очистки и нормализации текстов

После анализа структуры датасета, длины документов и наличия потенциальных аномалий был определён набор правил для очистки и нормализации текстов. Цель этого этапа заключалась в том, чтобы уменьшить влияние технического шума и привести письма к более однородному виду, не удаляя при этом информацию, которая может быть значимой для классификации. Для деловой переписки такой подход особенно важен, поскольку часть формально служебных элементов может быть связана с предметной областью, подразделением или конкретным типом документа.

Основные правила очистки включали приведение регистра, нормализацию пробельных символов, обработку технических фрагментов и унификацию типовых элементов. Для некоторых типов данных применялась замена на специальные токены. Такой подход позволяет сохранить сам факт наличия элемента в письме, но не привязывать модель к конкретному значению. Например, наличие ссылки или адреса электронной почты может быть полезным признаком, однако конкретный URL или конкретный адрес чаще всего не должны определять класс документа.

Отдельно учитывалось, что разные модели по-разному чувствительны к предобработке. Для TF-IDF-признаков очистка помогает уменьшить размер словаря и снизить число случайных n -грамм, возникающих из-за технических строк и уникальных значений. Для BERT-подобных моделей чрезмерная очистка может быть нежелательной, так как она нарушает естественную структуру текста. Поэтому итоговый набор правил должен был сохранять связность письма и не превращать документ в набор искусственных токенов.

2.5 Итоговое состояние данных после предобработки

После применения правил очистки количество объектов сократилось с 1774 до 1755. При этом число классов не изменилось и осталось равным 36, что важно для сохранения исходной постановки задачи. Удалённые объекты относились к технически некорректным или недостаточно содержательным записям и не приводили к исчезновению каких-либо классов из датасета.

Более заметным изменением стало сокращение общего объёма текстов. До очистки суммарный объём корпуса составлял 5 186 469 символов, после очистки — 2 173 226 символов. Таким образом, было удалено более половины символьного объёма корпуса. Это связано с устранением служебных блоков, повторяющихся фрагментов, технических элементов и других частей писем, которые создавали шум для моделей классификации. Распределения длины документов после очистки представлены на рисунках 2.4 и 2.5

При этом предобработка выполнялась аккуратно, без агрессивного стемминга или лемматизации, чтобы не разрушить специфические доменные термины и названия подразделений. В частности, сохранялись ключевые аббревиатуры и буквенно-цифровые обозначения, потенциально влияющие на класс объекта. Такой компромиссный подход обеспечивает баланс между снижением шума и сохранением важной предметной информации.



Рисунок 2.4 — Распределение длины документов по числу символов



Рисунок 2.5 — Распределение длины документов по числу слов или токенов

2.6 Особенности train/test-разбиения и распределения классов

После очистки и нормализации данных был сформирован итоговый корпус для проведения экспериментов. Он был разделён на обучающую и тестовую выборки. Обучающая часть использовалась для построения признаков, обучения моделей, аугментации и подбора вариантов обработки текста. Тестовая часть сохранялась отдельно и применялась только для итоговой оценки качества классификации.

Таблица 2.1 — Структура train/test-разбиения после очистки данных

Часть выборки	Количество документов	Количество классов
Train	1404	36
Test	351	36
Всего	1755	36

Разбиение выполнялось с сохранением представительности классов, насколько это возможно при имеющемся дисбалансе. Для данной задачи это особенно важно, так как в датасете присутствуют как крупные классы, содержащие сотни документов, так и редкие классы, представленные единичными или малочисленными примерами. Если при разделении данных какой-либо редкий класс исчез бы из тестовой выборки, итоговая оценка не отражала бы качество классификации по полному множеству классов. На рисунках 2.6, 2.7 проиллюстрировано финальное распределение классов.



Рисунок 2.6 — Распределение классов в обучающей выборке




Рисунок 2.7 — Распределение классов в тестовой выборке

Несмотря на сохранение всех классов в обеих частях, распределение остаётся несбалансированным. Крупные категории представлены значительно большим числом документов, чем редкие. Такая структура соответствует реальному характеру деловой переписки: по одним направлениям поток писем формируется постоянно, тогда как другие проекты или подразделения встречаются заметно реже. Поэтому дисбаланс не рассматривался как ошибка данных, а учитывался как одно из условий задачи.

Особенность выбранного разбиения заключается также в том, что тестовая выборка не изменялась на последующих этапах работы. Аугментация, суммаризация обучающих представлений и другие способы расширения данных применялись только к train-части. Это позволило избежать утечки информации из теста в обучение и сохранить корректность сравнения разных моделей. Все методы оценивались на одной и той же тестовой выборке, что делает результаты сопоставимыми между собой.

3 Постановка задачи и проектирование решения

3.1 Формальная постановка задачи многоклассовой классификации

В рамках работы требуется построить программный пайплайн, который по тексту делового письма автоматически определяет его принадлежность к одному из заданных классов. На вход системе подаётся текст документа после этапа предобработки, на выходе формируется метка класса. Предсказание выполняется в режиме *single-label classification*: для каждого письма выбирается только одна итоговая категория.

Задача рассматривается в контролируемой постановке. Для обучающих объектов известны правильные метки, поэтому модели обучаются на парах «текст — класс». После обучения классификатор должен обобщать выявленные закономерности на новые письма, которые не использовались при настройке модели. Все сравниваемые подходы решают одну и ту же задачу, но отличаются способом преобразования текста в признаки и типом классификационной модели.

С инженерной точки зрения задача может быть представлена как последовательность этапов: подготовка текста, построение признакового представления, обучение классификатора и получение предсказания. В качестве признакового представления могут использоваться разреженные TF-IDF-векторы, плотные BERT-эмбединги, суммаризованные варианты текста или композитные векторы. Такой подход позволяет не привязывать постановку задачи к одному конкретному алгоритму и сравнивать несколько решений в едином формате.

3.2 Требования к разрабатываемому решению

Разрабатываемое решение должно обеспечивать полный цикл обработки текстов: от подготовки исходных писем до обучения моделей и сравнения результатов классификации. Поскольку задача относится к прикладной классификации деловой переписки, решение должно быть не только экспериментальным, но и воспроизводимым. Это означает, что для каждого этапа должны быть зафиксированы входные данные, правила обработки, параметры моделей и используемые метрики качества.

3.3 Влияние предметной области на проектирование решения

Предметная область оказывает существенное влияние на выбор методов обработки и классификации текстов. В рассматриваемой задаче документы это длинные деловые письма, связанные с проектами, подразделениями и управленческими направлениями. Для деловой переписки важны как точные лексические совпадения, так и общий контекст письма. Отдельной особенностью является тематическая близость классов. Письма из разных категорий могут использовать похожий деловой язык: согласование, направление документов, контроль сроков, подготовка материалов, организационные вопросы.

3.4 Общая архитектура пайплайна обработки и классификации текста

Разрабатываемое решение построено как модульный пайплайн обработки и классификации текстов. Такой подход был выбран для того, чтобы разделить экспериментальную часть на независимые этапы и упростить воспроизводимость результатов. Каждый крупный этап работы реализован отдельным скриптом или группой скриптов: подготовка данных, очистка, аугментация, суммаризация, построение

признаков, обучение моделей и расчёт метрик не смешиваются в одном файле, а выполняются как самостоятельные части общего процесса.

На первом этапе выполняется подготовка исходных данных. В этот блок входит чтение исходного файла, первичная очистка, нормализация текстов, проверка структуры данных и формирование итогового набора для экспериментов. Отдельная реализация этого этапа позволяет при необходимости повторно подготовить корпус без запуска обучения моделей. Это важно, так как очистка данных влияет на все последующие ветки экспериментов.

На втором этапе формируются дополнительные варианты обучающих данных. В отдельные модули вынесены методы аугментации, их общие части и специфичные под перефразирование и обратный перевод. Такой подход позволяет независимо запускать разные сценарии обогащения выборки и сравнивать их влияние на последующие модели. Для длинных документов в этих модулях дополнительно реализована логика разбиения текста на фрагменты, генерации вариантов и последующей сборки текста обратно в полный документ.

Отдельной веткой пайплайна является суммаризация. Она используется для построения сокращённых версий документов и комбинированных представлений, где исходный текст дополняется его кратким содержанием. Выделение суммаризации в самостоятельный блок позволяет рассматривать её не как часть очистки, а как отдельный способ формирования альтернативного представления текста для классификации.

На следующем этапе выполняется построение признаковых представлений. Классическая ветка пайплайна отвечает за формирование TF-IDF-признаков на основе word и char ngram-представлений. Нейросетевая ветка включает работу с BERT-подобными моделями: получение эмбедингов, эксперименты с различными вариантами классификационных голов, а также обучение модели для длинных документов с использованием чанкинга. Отдельно реализована ветка композитных признаков, в которой объединяются TF-IDF-векторы и BERT-представления.

После построения признаков выполняется обучение классификаторов. Для разных типов представлений используются соответствующие модели: LinearSVC и LogisticRegression для разреженных TF-IDF-признаков, классические модели и MLP для эмбединговых и композитных векторов, а также нейросетевые классификаторы на основе ruBERT и ruRoberta-large. Благодаря модульной структуре можно запускать отдельные эксперименты независимо и не пересчитывать те этапы, которые уже были выполнены.



Рисунок 3.1 — Архитектура пайплайна обработки и классификации текста

В общем виде пайплайн можно представить как последовательность связанных, но независимых блоков: подготовка данных → предобработка → аугментация и суммаризация → построение признаков → обучение моделей → оценка качества. Такая архитектура делает решение расширяемым: при добавлении нового метода достаточно реализовать отдельный модуль и подключить его к уже существующим данным и протоколу оценки. Это особенно важно для исследовательской работы, где в процессе экспериментов проверяется несколько альтернативных подходов к представлению и классификации текстов.

3.5 Выбор направлений моделирования

Первым направлением стали классические модели на основе TF-IDF-признаков. Этот подход был выбран как базовая линия, поскольку он хорошо подходит для задач классификации текстов на небольших и средних выборках, быстро обучается и позволяет использовать как словные, так и символьные n-граммы. В работе отдельно рассматриваются word-признаки, char-признаки и их объединение. Поверх полученных векторов обучаются линейные классификаторы, в том числе LinearSVC и LogisticRegression.

Вторым направлением стали BERT-подобные модели. Они были выбраны для проверки того, насколько контекстные представления помогают в задаче классификации длинных русскоязычных деловых писем. В рамках этого направления рассматриваются ruBERT и ruRoberta-large, а также разные варианты использования выхода модели: классификация с использованием AutoModel, mean pooling и полноценный классификатор для длинных документов с чанкингом.

Третьим направлением стало построение эмбединговых представлений документов. В отличие от end-to-end классификации BERT, здесь модель используется для получения векторов текстов, после чего поверх этих векторов обучаются отдельные классификаторы. Такой подход позволяет отделить этап построения признаков от этапа классификации и проверить, насколько информативными являются плотные представления для данной предметной области.

Четвёртым направлением стали композитные признаки. В этом варианте разреженные TF-IDF-векторы объединяются с плотными BERT-представлениями. Идея заключается в том, чтобы совместить точные лексические признаки, полезные для деловых текстов, и контекстную информацию, извлекаемую нейросетевыми моделями. Для классификации таких объединённых векторов рассматриваются классические модели и MLP-классификатор.

3.6 Использование суммаризации для подготовки дополнительных представлений текста

Использование суммаризации позволяет проверить гипотезу о том, что сокращённая версия письма может быть более компактным и менее шумным представлением документа. Если суммаризация сохраняет ключевую информацию, классификатор может получать более сфокусированный текст, в котором меньше повторов и технических элементов. Это особенно важно для BERT-подобных моделей, у которых есть ограничение на длину входной последовательности.

В работе суммаризация рассматривается как дополнительный этап подготовки данных, а не как замена основной предобработки.

3.7 Построение суммаризованного и комбинированного наборов данных

Для проверки влияния суммаризации были сформированы дополнительные варианты набора данных. Первый вариант основан только на суммаризованных текстах. В этом случае вместо полного письма в модель передаётся его краткое содержание. Такой набор позволяет проверить, достаточно ли summary для сохранения признаков, необходимых для определения класса.

Второй вариант является комбинированным. В нём исходный текст объединяется с его суммаризованной версией. Такой подход выбран для того, чтобы не терять детали оригинального письма, но одновременно добавить к нему более компактное представление основного содержания. Комбинированный вариант можно рассматривать как способ обогащения текста: модель получает и полный документ, и его краткое смысловое описание.

При построении таких наборов важно сохранять соответствие между текстом и исходной меткой класса. При этом тестовая часть не используется для обучения моделей суммаризации или настройки классификаторов. Все варианты данных затем оцениваются в едином экспериментальном протоколе.

3.8 Выбор метрик качества классификации

Для оценки качества моделей в работе используются метрики, подходящие для многоклассовой классификации при несбалансированном распределении классов. В такой задаче недостаточно ориентироваться только на accuracy, поскольку высокая общая точность может достигаться за счёт правильной классификации крупных классов, при этом качество на редких категориях может оставаться низким.

Основными метриками выбраны balanced accuracy и macro F1. Balanced accuracy позволяет учитывать качество распознавания по каждому классу и снижает влияние доминирующих категорий. Macro F1 также важна для данной задачи, так как рассчитывается с равным вкладом каждого класса и показывает, насколько устойчиво модель работает не только на крупных, но и на малых категориях.

Выбор таких метрик связан с особенностями исходной задачи. Поскольку в данных присутствуют классы с разным количеством документов, итоговая оценка должна показывать не только способность модели распознавать наиболее частые категории, но и её устойчивость на всём множестве классов. Поэтому в финальном сравнении основное внимание уделяется balanced accuracy и macro F1, а остальные показатели используются для дополнительной интерпретации результатов.

4 Аугментация данных и обогащение выборки

4.1 Мотивация аугментации при дисбалансе классов

Как показал разведочный анализ данных, присутствуют классы которые содержат всего 1 пример в тренировочной выборке. Есть и менее критичные примеры, но без аугментации у моделей не будет шансов определять такие классы.

4.2 Аугментация классическими методами без использования нейросетевых моделей

Случайное удаление слов, замена синонимами, случайная перестановка слов и другие методы не показали улучшения метрик на методах классификации и в итоговый пайплайн не вошли.

4.3 Общая схема нейросетевой аугментации длинных текстов

Основная аугментация в работе выполняется двумя нейросетевыми методами: перефразированием и обратным переводом. Несмотря на различие самих моделей, общая схема обработки для этих методов имеет сходную структуру. Это позволяет применять единый подход к длинным деловым письмам и контролировать качество получаемых текстов.

Сначала в тексте маскируются чувствительные и структурно важные фрагменты, такие как персоналии, организации и даты. Для этого используются специальные placeholder-обозначения вида <PH_i>. Маскирование необходимо для того, чтобы генеративная модель не искажала такие элементы и не создавала некорректные варианты имён, организаций или временных выражений.

Затем документ разделяется на фрагменты. Полученные тексты с разными гиперпараметрами подаются нейросетевым моделям. Происходит генерация нескольких примеров с выбором лучшего из них. Полученные новые части документа конкатенируются обратно. Получившееся аугментация сравнивается на схожесть со всеми оригинальными документами класса. Если проверка пройдена пример добавляется, иначе алгоритм переключается на другой пример класса. Если не удалось за фиксированное число повторений составить ни одного нового примера, то метка для аугментации переключается. Это нужно чтобы не заикливаясь на сложных примерах и вернуться к ним позже, после того как будут пройдены все простые примеры.

4.4 Разбиение текста на предложения и фрагменты при аугментации

Для применения нейросетевой аугментации длинный документ сначала разбивается на более короткие части. На первом шаге используется разбиение текста на предложения. Такой подход позволяет работать с естественными смысловыми фрагментами, а не с произвольными отрезками текста. Это особенно важно для деловых писем, где одно предложение может содержать отдельное поручение, просьбу, описание ситуации или ссылку на документ.

Однако в деловой переписке встречаются длинные предложения, которые могут превышать допустимую или удобную длину для генеративной модели. Поэтому после разбиения на предложения выполняется дополнительное деление длинных предложений на фрагменты. В реализации используется рекурсивное разбиение по пунктуации, а при необходимости — по словам. Целевая длина фрагмента ограничивается, чтобы текст оставался удобным для обработки моделью.

Если предложение невозможно корректно разделить по пунктуации, применяется аварийное разбиение на окна фиксированного размера. Такой механизм нужен для устойчивости пайплайна: даже нестандартные или плохо структурированные фрагменты письма должны быть обработаны без остановки всей аугментации.

В результате каждый исходный документ представляется как последовательность фрагментов. Каждый фрагмент аугментируется отдельно, после чего итоговые варианты объединяются обратно. Это позволяет применять перефразирование и обратный перевод к длинным письмам, не теряя структуру документа полностью.

4.5 Генерация нескольких вариантов аугментации и выбор итогового кандидата

Для каждого фрагмента текста генерируется не один, а несколько вариантов аугментации. Это необходимо потому, что результат генеративной модели может отличаться по качеству: один вариант может быть слишком близким к исходному тексту, другой — слишком свободным, третий — содержать неудачную формулировку. Генерация нескольких кандидатов позволяет выбрать наиболее подходящий вариант для включения в итоговый документ.

В методе обратного перевода используются несколько языков-посредников и разные режимы генерации. Это даёт набор альтернативных формулировок для одного и того же исходного фрагмента. В методе перефразирования также используются несколько режимов генерации, включая beam search и sampling. За счёт этого модель может создавать варианты с разной степенью близости к исходной формулировке.

Выбор кандидата выполняется по набору критериев. На первом уровне проверяется техническая пригодность текста: кандидат не должен быть пустым, чрезмерно коротким или полностью совпадать с оригиналом. Далее оценивается близость к исходному фрагменту. Для этого используется косинусное сходство между эмбедингами исходного и сгенерированного текста. Подходящий кандидат должен сохранять смысл исходного фрагмента, но при этом не быть его точной копией.

Для обратного перевода дополнительно используется оценка языковой естественности через перплексию языковой модели. Это помогает выбирать более гладкие и грамматически приемлемые варианты. В результате в итоговый текст попадают не все сгенерированные фрагменты, а только те, которые прошли фильтрацию и соответствуют заданным ограничениям.

4.6 Схема доведения редких классов до порогового размера выборки

Аугментация применялась прежде всего для увеличения количества примеров в редких классах. В работе используется схема доведения малых классов до заданного порогового размера. Это означает, что для каждого класса анализируется текущее количество документов, после чего дополнительные примеры генерируются только в том объёме, который необходим для приближения класса к целевому уровню.

В реализации используется целевое значение `TARGET_PER_CLASS = 30`. Если класс содержит меньше документов, чем заданный порог, для него запускается генерация новых примеров на основе исходных текстов обучающей выборки. При этом исходные документы перебираются циклически, а число попыток ограничивается, чтобы избежать бесконечной генерации для классов, где модель не может получить достаточно качественных кандидатов.

Каждый новый пример проходит несколько фильтров. Проверяется длина текста, отличие от исходного документа, косинусное сходство с оригиналом и соответствие классовому пространству. Дополнительно контролируется близость кандидата к эмбедингам текстов того же класса. Это позволяет уменьшить вероятность включения

примеров, которые формально сгенерированы из исходного документа, но слишком сильно смещены по смыслу.

Такая стратегия позволяет не увеличивать все классы одинаково, а направить генерацию туда, где данных действительно недостаточно. Это особенно важно для несбалансированного датасета, так как полное равномерное размножение всех классов могло бы привести к избыточному росту корпуса без существенной пользы.

4.7 Аугментация с использованием перефразирования

Перефразирование используется для получения новых вариантов текста с сохранением исходного смысла. В этом подходе модель получает фрагмент письма и генерирует альтернативную формулировку на русском языке. Такой метод хорошо подходит для задачи классификации, так как позволяет увеличить разнообразие выражений внутри одного класса без изменения целевой метки.

В работе для перефразирования использовалась модель семейства `ruT5`. Она применялась как генеративная `seq2seq`-модель: на вход подавался исходный фрагмент текста, а на выходе формировался его перефразированный вариант. Использование русскоязычной модели важно для данной задачи, поскольку исходные документы представляют собой деловые письма на русском языке, содержащие специфичные формулировки, названия проектов и служебные конструкции.

4.8 Аугментация методом обратного перевода

Обратный перевод является вторым нейросетевым методом аугментации, использованным в работе. Его идея заключается в том, что исходный русский текст переводится на промежуточный язык, а затем обратно на русский. При таком преобразовании часть формулировок изменяется, но общий смысл должен сохраняться. Это позволяет получить дополнительный вариант текста без ручного составления правил перефразирования.

Для реализации обратного перевода использовались модели машинного перевода семейства `Helsinki-NLP/OPUS-MT`. Перевод выполнялся по нескольким направлениям: с русского языка на промежуточный язык и затем обратно на русский. В качестве промежуточных языков использовались английский, французский и испанский. Такой выбор позволяет получать несколько разных вариантов переформулирования одного и того же фрагмента.

Метод обратного перевода особенно полезен тем, что он меняет структуру фразы более естественным образом, чем простые случайные замены слов. Однако он также может вносить искажения: термин может быть переведён неточно, деловая формулировка может стать менее естественной, а специфичные названия могут быть изменены. Поэтому перед переводом используются `placeholder`-маркеры для важных сущностей, а после генерации применяется фильтрация кандидатов.

При выборе итогового варианта учитывается семантическая близость к исходному фрагменту и языковая естественность текста. Для этого используется косинусное сходство и дополнительная оценка перплексии. Такой подход позволяет отобрать варианты, которые достаточно отличаются от оригинала, но сохраняют его содержание и остаются пригодными для обучения классификатора.

4.9 Фильтрация аугментированных текстов по косинусному сходству

Фильтрация по косинусному сходству используется как основной механизм контроля качества аугментированных текстов. После генерации необходимо убедиться, что новый текст сохраняет смысл исходного документа, но не является его точной копией. Для этого исходный и аугментированный текст переводятся в векторное пространство, после чего между ними вычисляется косинусное сходство.

В работе для получения эмбеддингов используется модель `deepvk/USER2-base`. Эмбеддинги нормализуются, а сходство вычисляется с помощью косинусной меры. Такой подход позволяет оценивать близость не только по совпадению слов, но и по общему смысловому содержанию. Это особенно важно для перефразирования и обратного перевода, где формулировки могут изменяться, но смысл должен оставаться близким к исходному.

Для отбора кандидатов задаются допустимые интервалы сходства. Если сходство слишком низкое, это может означать, что сгенерированный текст ушёл от исходного смысла. Если сходство слишком высокое, текст почти не отличается от оригинала и не добавляет полезного разнообразия. Поэтому в аугментацию включаются только варианты, находящиеся в заданном диапазоне.

Дополнительно используется проверка близости кандидата к текстам того же класса. Это позволяет контролировать не только связь с исходным документом, но и соответствие общей области класса. Такой фильтр особенно важен для редких классов, где ошибочная аугментация может заметно повлиять на обучение модели.

4.10 Склейка аугментированных фрагментов в полный текст документа

Так как аугментация выполняется на уровне отдельных фрагментов, после генерации необходимо восстановить полный текст документа. Для этого выбранные аугментированные фрагменты объединяются в исходном порядке. Такая схема позволяет сохранить общую структуру письма: последовательность абзацев, логика изложения и порядок смысловых частей остаются близкими к оригинальному документу.

После объединения фрагментов выполняется демаскирование `placeholder`-элементов. На этом этапе специальные обозначения, временно использованные для защиты персональных данных, организаций и дат, заменяются обратно на исходные значения. Это позволяет сохранить важные структурные элементы письма и избежать искажений, которые могли бы появиться при генерации.

Далее применяется постобработка сгенерированного текста. Она включает очистку лишних пробелов, исправление технических артефактов генерации и приведение текста к формату, совместимому с остальными данными. Такой этап необходим, поскольку при фрагментарной генерации могут появляться небольшие несогласованности на границах частей.

Склейка фрагментов является важной частью пайплайна, так как итоговая модель классификации работает с полным документом. Поэтому результат аугментации должен представлять собой не набор отдельных предложений, а полноценный текст письма. Это позволяет использовать аугментированные данные в тех же моделях, что и исходные документы.

4.11 Формирование итогового аугментированного набора данных

После генерации перефразированных и обратно переведённых документов были сформированы отдельные аугментированные наборы данных. Для каждого метода

сохранялся собственный результат, что позволяло анализировать вклад разных способов аугментации. Отдельно были получены наборы на основе обратного перевода и перефразирования.

Затем результаты разных методов были объединены в общий аугментированный набор. При объединении выполнялась дедупликация по паре «метка класса — нормализованный текст», чтобы избежать попадания одинаковых объектов. После объединения данные перемешивались с фиксированным значением random state, что обеспечивало воспроизводимость дальнейших экспериментов.

Таблица 4.1 — Сформированные наборы данных после аугментации

Набор данных	Количество объектов	Описание
train.csv	1404	Исходная обучающая выборка после очистки
train_backtranslate.csv	1845	Обучающая выборка с обратным переводом
train_paraphrase.csv	1833	Обучающая выборка с перефразированием
train_augmented.csv	2163	Объединённый аугментированный набор

Кроме основного аугментированного набора, далее формировались дополнительные варианты для экспериментов с суммаризацией: суммаризованный аугментированный набор и комбинированный вариант, в котором исходный текст объединяется с summary. Эти данные используются в последующих экспериментах как альтернативные представления обучающей выборки.

Важно, что тестовая выборка при формировании аугментированных данных не изменялась. Это позволяет оценивать все модели на одном и том же наборе документов и сравнивать влияние разных вариантов обучения без изменения тестового протокола.

4.12 Анализ распределения данных после аугментации

После формирования аугментированного набора был выполнен анализ распределения классов. Цель этого этапа заключалась в том, чтобы проверить, насколько аугментация изменила структуру обучающей выборки и удалось ли увеличить количество примеров в редких категориях. Поскольку генерация выполнялась преимущественно для малых классов, распределение после аугментации должно стать более сбалансированным по сравнению с исходным train-набором.



Рисунок 4.1 — Распределение классов в обучающей выборке после аугментации

Анализ показал, что большинство редких классов было увеличено до заданного порогового уровня или приблизилось к нему. При этом крупные классы не размножались пропорционально, что позволило избежать чрезмерного роста уже доминирующих категорий. Таким образом, аугментация была направлена именно на выравнивание обучающего распределения, а не на простое увеличение общего числа документов.

В итоговом объединённом наборе `train_augmented.csv` содержится 2163 объекта. По сравнению с исходной обучающей выборкой объём данных увеличился, при этом все документы сохраняют одну из исходных 36 меток классов. Это позволяет использовать аугментированный набор в тех же моделях классификации, что и исходный `train`-набор.

Итоговый аугментированный набор далее используется в экспериментах с классическими моделями, BERT-подходами, эмбединговыми и композитными представлениями. Это позволяет оценить влияние обогащения данных на разные типы классификаторов в едином сравнительном протоколе.

5 Классические модели на основе разреженных текстовых признаков

5.1 Теоретические основы TF-IDF-представления текста

TF-IDF является одним из базовых способов преобразования текста в числовое признаковое пространство. В таком представлении документ описывается через набор токенов или n-грамм, а каждому признаку сопоставляется вес. Чем чаще признак встречается в конкретном документе и чем реже он встречается во всём корпусе, тем более информативным он считается для данного документа.

Для задачи классификации деловых писем TF-IDF-подход имеет несколько преимуществ. Во-первых, он хорошо работает с небольшими и средними по размеру наборами данных, где сложные нейросетевые модели могут не получить достаточного количества примеров для устойчивого дообучения. Во-вторых, TF-IDF позволяет явно учитывать слова, словосочетания, служебные обозначения и характерные фрагменты, которые могут быть связаны с конкретным классом. В деловой переписке такими признаками могут быть названия проектов, подразделений, типовые формулировки, внутренние аббревиатуры и устойчивые конструкции.

В отличие от плотных эмбедингов, TF-IDF формирует разреженное пространство признаков. Это означает, что каждому документу соответствует вектор большой размерности, где большинство значений равно нулю. Такая структура естественна для текстов, поскольку один документ содержит только небольшую часть всех возможных слов и n-грамм корпуса. При этом линейные классификаторы хорошо приспособлены к работе с такими признаками и позволяют быстро обучаться даже на больших разреженных матрицах.

В данной работе TF-IDF используется как основа классической ветки моделирования. На его базе строятся признаки разных типов: словные n-граммы, символные n-граммы и их объединение. Такой набор вариантов позволяет проверить, какие уровни текстовой информации оказываются наиболее полезными для классификации длинных русскоязычных деловых писем.

5.2 Линейные классификаторы для разреженных текстовых признаков

Для классификации TF-IDF-признаков в работе используются линейные модели. Их выбор связан с тем, что они хорошо работают с высокоразмерными разреженными представлениями и обычно дают устойчивый результат в задачах классификации текстов. Линейная модель обучает вес для каждого признака и на основе взвешенной суммы признаков принимает решение о принадлежности документа к классу.

Основными классификаторами в классической ветке являются LinearSVC и LogisticRegression. LinearSVC основан на линейной версии метода опорных векторов и хорошо подходит для задач, где данные представлены большим количеством разреженных признаков. LogisticRegression также является линейной моделью, но интерпретирует задачу через оценку вероятностей классов. Оба подхода позволяют эффективно работать с TF-IDF-представлениями и быстро обучаются на CPU.

С учётом дисбаланса классов в обеих моделях используется параметр `class_weight="balanced"`. Он позволяет автоматически учитывать различие в количестве объектов по классам и уменьшает смещение модели в сторону наиболее крупных категорий. Это особенно важно для рассматриваемой задачи, где часть классов представлена существенно меньшим числом документов.

Дополнительно в экспериментах рассматривался MultinomialNB. Этот классификатор часто используется как простой базовый метод для текстовой классификации. Он позволяет получить дополнительную точку сравнения для TF-IDF-

признаков, хотя основное внимание в работе уделяется линейным моделям, которые обычно лучше подходят для разреженных признаков большой размерности.

5.3 Построение признаков на основе word n-грамм

Первый вариант TF-IDF-представления строится на основе словных n-грамм. В этом случае признаками являются отдельные слова и последовательности из нескольких слов. Такой подход позволяет учитывать не только наличие конкретных терминов, но и устойчивые словосочетания, которые могут быть характерны для определённого класса.

В реализации используется `TfidfVectorizer` со значением `analyzer="word"` и диапазоном `ngram_range=(1, 2)`. Это означает, что в признаковое пространство включаются униграммы и биграммы. Униграммы отражают отдельные слова, а биграммы позволяют учитывать короткие устойчивые сочетания, например названия направлений, типовые деловые обороты или фразы, связанные с конкретной категорией.

5.4 Построение признаков на основе символьных char n-грамм

Второй вариант TF-IDF-представления строится на основе символьных n-грамм. В отличие от word-признаков, здесь единицами анализа являются не слова, а фрагменты строк фиксированной длины. Такой подход полезен для русского языка, поскольку позволяет частично учитывать морфологические изменения слов, окончания, приставки, сокращения и варианты написания.

В реализации используется `TfidfVectorizer` со значением `analyzer="char_wb"` и диапазоном `ngram_range=(3, 5)`. Параметр `char_wb` означает, что символьные n-граммы строятся внутри границ слов. Это помогает уменьшить количество случайных признаков, возникающих при построении n-грамм через пробелы или границы разных слов, и делает признаки более устойчивыми.

Для ограничения словаря используются параметры `min_df=2` и `max_df=0.95`. Первый параметр исключает слишком редкие символьные фрагменты, которые встречаются только в единичных документах и могут быть шумом. Второй параметр исключает слишком частые признаки, присутствующие почти во всём корпусе и слабо помогающие различать классы.

Символьные признаки особенно полезны в деловой переписке, где встречаются аббревиатуры, служебные обозначения, проектные названия и разные формы одних и тех же слов. Даже если полные слова отличаются, их символьные фрагменты могут частично совпадать и давать модели дополнительную информацию для классификации.

5.5 Комбинирование word- и char-признаков в едином признаковом пространстве

Поскольку word- и char-признаки отражают разные свойства текста, в работе используется их объединение в одном признаковом пространстве. Word n-граммы хорошо фиксируют отдельные слова и короткие словосочетания, а char n-граммы позволяют учитывать внутреннюю структуру слов и устойчивы к морфологическим изменениям. Для русскоязычных деловых писем такое сочетание является полезным, так как в данных одновременно присутствуют предметные термины, аббревиатуры, служебные обозначения и разные формы слов.

Для объединения признаков используется `FeatureUnion`. В него включаются два независимых векторизатора: word TF-IDF и char TF-IDF. Каждый из них строит собственное признаковое пространство, после чего полученные матрицы объединяются в общий разреженный вектор документа.

В итоговом пайплайне объединённое представление передаётся в классификатор как единый набор признаков. Такой подход позволяет модели одновременно использовать точные словные совпадения и более гибкие символьные признаки. Это особенно важно для предметной области, где одни классы могут отличаться конкретными названиями и формулировками, а другие — более размытыми лексическими паттернами.

5.6 Реализация пайплайна TF-IDF + LinearSVC

Основным классическим baseline в работе является пайплайн TF-IDF + LinearSVC. Он реализован как последовательность этапов: построение TF-IDF-признаков и обучение линейного классификатора. Такой подход выбран как сильная и вычислительно эффективная базовая линия для задачи многоклассовой классификации текстов.

В качестве признакового пространства используется объединение word- и char-признаков. Word-компонента строится на униграммах и биграмах, а char-компонента — на символьных n-граммах длины от 3 до 5. Далее объединённый разреженный вектор передаётся в LinearSVC.

Использование сбалансированных весов классов связано с неравномерным распределением документов в обучающей выборке. В этом режиме модель учитывает частоты классов и увеличивает вклад редких категорий при обучении. Это позволяет сделать baseline более устойчивым к дисбалансу.

Данный пайплайн имеет несколько практических преимуществ. Он быстро обучается на CPU, не требует GPU и хорошо масштабируется на разреженные признаки. Кроме того, его удобно использовать как контрольную точку для сравнения с более сложными подходами: BERT-моделями, эмбединговыми классификаторами и композитными представлениями.

5.7 Реализация пайплайна TF-IDF + LogisticRegression

Второй линейный классификатор, использованный в классической ветке, — LogisticRegression. Он применяется поверх того же TF-IDF-представления, что и LinearSVC, что позволяет сравнить влияние классификационной модели при одинаковом способе построения признаков.

LogisticRegression полезна как альтернативная линейная модель, поскольку она отличается от LinearSVC способом оптимизации и интерпретацией выходов. В то время как LinearSVC ориентирован на построение разделяющих гиперплоскостей с максимальным зазором, LogisticRegression обучается в вероятностной постановке. Это делает её удобной дополнительной моделью для проверки устойчивости TF-IDF-признаков.

В рамках работы LogisticRegression рассматривается не как замена основному baseline, а как дополнительный классический классификатор. Его использование позволяет убедиться, что результаты классической ветки зависят не только от одного выбранного алгоритма, но и от качества самого признакового представления.

5.8 Дополнительные классические модели классификации

Помимо LinearSVC и LogisticRegression, в экспериментах рассматривался MultinomialNB. Это один из традиционных классификаторов для текстовых задач, особенно часто используемый совместно с частотными или TF-IDF-признаками. Его включение в набор экспериментов позволяет получить простую дополнительную точку сравнения для классических методов.

MultinomialNB основан на вероятностной модели распределения признаков по классам. В задачах классификации текстов он может работать быстро и стабильно, особенно когда признаки являются неотрицательными и отражают частоты или веса слов. При этом модель делает более сильные предположения о независимости признаков, чем линейные классификаторы, поэтому она используется как вспомогательный baseline.

В классической ветке также проводились эксперименты с разными вариантами признаков: только word TF-IDF, только char TF-IDF и объединение word+char. Это позволяет разделить влияние двух факторов: выбранного классификатора и выбранного способа векторизации текста. Такой подход делает сравнение более полным, поскольку одна и та же модель может вести себя по-разному на разных типах признаков.

Отдельно проверялось влияние нормализации текста перед построением TF-IDF-признаков. Для этого в экспериментальных скриптах использовался вариант пайплайна с дополнительным преобразованием текста через FunctionTransformer. Такой эксперимент позволяет оценить, насколько предварительная нормализация влияет на качество классических моделей.

5.9 Особенности применения TF-IDF к длинным деловым письмам

Применение TF-IDF к длинным деловым письмам имеет как преимущества, так и ограничения. Одним из главных преимуществ является отсутствие жёсткого ограничения на длину входного текста. В отличие от BERT-подобных моделей, которые принимают ограниченное число токенов, TF-IDF может использовать весь текст документа. Это особенно важно для писем, где значимая информация может находиться не только в начале, но и в середине или конце.

Для деловых писем также полезно то, что TF-IDF хорошо фиксирует характерные лексические признаки. Внутренние названия, проектные обозначения, аббревиатуры, типовые фразы и устойчивые словосочетания могут быть напрямую отражены в признаковом пространстве. При использовании word- и char-ngram-представлений модель получает доступ как к полным словам, так и к их фрагментам.

Однако длинные документы также создают сложности. Они могут содержать большое количество служебных и повторяющихся фрагментов: подписи, пересланную переписку, реквизиты, списки приложений, технические строки. Если такие элементы не обработаны на этапе предобработки, они могут увеличивать размер словаря и создавать шумовые признаки. Поэтому качество TF-IDF-подхода во многом зависит от предварительной очистки данных.

В данной работе TF-IDF используется не только как простой baseline, но и как важная часть общего исследования текстовых представлений. Сначала он применяется в классических моделях, затем его признаки используются при построении композитного векторного пространства вместе с BERT-представлениями. Это позволяет рассматривать TF-IDF как самостоятельный метод и как компонент более сложного признакового описания документа.

6 Контекстные представления и классификация на основе BERT-моделей

6.1 Теоретические основы transformer-архитектур

Нужно заполнить.

6.2 Контекстные эмбединги и их отличие от разреженных признаков

Нужно заполнить.

6.3 Используемые русскоязычные модели ruBERT и ruRoberta-large

Нужно заполнить.

6.4 Два подхода к использованию BERT в задаче классификации

Нужно заполнить.

6.4.1 Дообучение BERT/Sentence-BERT для построения эмбедингов

Нужно заполнить.

6.4.2 Дообучение BERT как end-to-end классификатора

Нужно заполнить.

6.5 Классификация текстов с использованием выхода AutoModel

Нужно заполнить.

6.6 Классификация текстов с использованием mean pooling

Нужно заполнить.

6.7 Построение Sentence-BERT-представлений документов

Нужно заполнить.

6.8 Эксперименты с ruBERT-base-cased и различными классификационными головами

Нужно заполнить.

6.9 Эксперименты с ruRoberta-large и различными классификационными головами

Нужно заполнить.

6.10 Ограничение длины входной последовательности и проблема длинных документов

Нужно заполнить.

6.11 Разбиение длинных текстов на перекрывающиеся чанки

Нужно заполнить.

6.12 Агрегация представлений чанков на уровне документа

Нужно заполнить.

6.13 Архитектура основного классификатора для чанкированных документов

Нужно заполнить.

6.14 Параметры обучения ruRoberta-large с чанкингом

Нужно заполнить.

6.15 Регуляризация и стабилизация обучения на малой выборке

Нужно заполнить.

7 Композитные и эмбединговые представления текста

7.1 Построение BERT-эмбедингов документов

Нужно заполнить.

7.2 Использование эмбедингов предобученной модели

Нужно заполнить.

7.3 Использование эмбедингов дообученной модели

Нужно заполнить.

7.4 Классические классификаторы поверх плотных эмбедингов

Нужно заполнить.

7.5 Классификация по центроидам классов

Нужно заполнить.

7.6 Классификация методом ближайшего соседа

Нужно заполнить.

7.7 Конкатенация TF-IDF и BERT-векторов

Нужно заполнить.

7.8 Реализация композитного признакового пространства

Нужно заполнить.

7.9 Использование классических моделей и MLP-классификатора поверх композитных векторов

Нужно заполнить.

8 Программная реализация разработанного пайплайна

8.1 Общая структура программного решения

Нужно заполнить.

8.2 Модуль предобработки данных

Нужно заполнить.

8.3 Модуль аугментации текстов

Нужно заполнить.

8.4 Модуль построения векторных представлений

Нужно заполнить.

8.5 Модуль обучения моделей

Нужно заполнить.

8.6 Воспроизводимость экспериментов

Нужно заполнить.

8.7 Ограничения реализации и требования к вычислительным ресурсам

Нужно заполнить.

9 Экспериментальное исследование и сравнение результатов

9.1 Экспериментальный протокол оценки качества

Нужно заполнить.

9.2 Используемые метрики качества классификации

Нужно заполнить.

9.3 Сравнение качества на исходной и аугментированной обучающей выборке

Нужно заполнить.

9.4 Сравнение исходных, суммаризованных и комбинированных текстовых представлений

Нужно заполнить.

9.5 Сводная таблица результатов всех реализованных подходов

Нужно заполнить.

9.6 Анализ влияния аугментации на качество классификации

Нужно заполнить.

9.7 Сравнение классических, нейросетевых и композитных представлений

Нужно заполнить.

9.8 Выводы по результатам экспериментального исследования

Нужно заполнить.

ЗАКЛЮЧЕНИЕ

В выпускной квалификационной работе была рассмотрена задача построения и применения композитных векторных представлений текста для многоклассовой классификации текстов на примере реального корпоративного датасета с выраженным дисбалансом классов. В ходе исследования проведён полный цикл разработки прототипа системы: от разведочного анализа и предобработки исходных данных до реализации классических и нейросетевых моделей классификации, а также экспериментальной оценки влияния текстовой аугментации на качество решений.

На этапе разведочного анализа данных была изучена структура датасета, распределение классов, длина текстов и наличие дубликатов и аномальных объектов. Показано, что исходные данные характеризуются значительным дисбалансом по классам и содержат как слишком короткие, так и сложные многокомпонентные записи, что существенно усложняет задачу обучения устойчивых моделей. Были сформулированы и реализованы правила предобработки и нормализации текстов, позволяющие уменьшить количество шума и привести данные к унифицированному виду при сохранении важных доменных терминов и обозначений.

Для компенсирования дисбаланса и обогащения малочисленных классов разработано два сценария текстовой аугментации: перефразирование и обратный перевод. Реализованные методы позволили существенно выровнять распределение объектов по классам и увеличить вариативность формулировок, что создало более благоприятные условия для обучения как классических, так и нейросетевых моделей.

В качестве базового решения был построен классический пайплайн на основе TF-IDF-представления текста и линейного классификатора LinearSVC. При обучении на исходном датасете без аугментации эта модель достигла сбалансированной точности порядка 0,443 и макро-усреднённой F1-меры порядка 0,44, что отражает ограниченную способность к распознаванию редких классов. Подключение аугментации привело к последовательному улучшению метрик: при обучении на наборах с перефразированием и обратным переводом сбалансированная точность выросла до 0,462–0,463, а макро-F1 — до 0,466–0,472; на объединённом аугментированном датасете baseline-модель достигла balanced accuracy 0,463 и macro F1 0,472.

Основным направлением повышения качества стала реализация нейросетевой модели классификации на основе предобученного русского трансформера ruBERT. На исходном датасете без аугментации данная модель показала значения сбалансированной точности и макро-F1 порядка 0,387, что сопоставимо с базовой моделью и подчёркивает сложность исходной задачи при ограниченном количестве данных. При обучении на наборах с перефразированием и обратным переводом метрики ruBERT выросли до balanced accuracy 0,429–0,431 и macro F1 0,423–0,424, а при использовании объединённого аугментированного набора модель достигла сбалансированной точности около 0,648 и макро-F1 порядка 0,641, что существенно превосходит результаты классического подхода.

Проведён сравнительный анализ метрик качества моделей на разных вариантах обучающих наборов, а также анализ ошибок и трудных классов. Это позволило выявить типичные пары смешиваемых категорий и классы с устойчиво низкими значениями F1-меры, что связано как с ограниченностью данных, так и с пересечением смысловых областей. На основе этих наблюдений сформулированы рекомендации по дальнейшему улучшению качества: уточнение схем аугментации, возможный пересмотр структуры классов и внедрение более сложных стратегий обучения с учётом дисбаланса.

Главным результатом работы является разработка модульного программного прототипа, включающего последовательные этапы предобработки, аугментации, построения векторных представлений и обучения моделей классификации, а также набор экспериментальных результатов, демонстрирующих преимущества современных нейросетевых подходов и текстовой аугментации для многоклассовой классификации корпоративных текстов. В процессе исследования также заложена основа для последующей работы с композитными векторными представлениями, предполагающей комбинирование классических и контекстных эмбедингов и адаптивное взвешивание их вкладов в итоговый вектор текста.

Практическая значимость полученных результатов заключается в том, что разработанный прототип и предложенные подходы могут быть адаптированы для решения прикладных задач автоматической классификации корпоративных текстов, таких как маршрутизация обращений, категоризация внутренних документов и анализ инцидентов. Дальнейшее развитие работы видится в реализации и экспериментальной оценке композитных эмбедингов, расширении набора моделей и методик аугментации, а также интеграции прототипа в более крупные системы анализа текстовых данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

Статьи и материалы конференций:

1. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A.N., Kaiser L., Polosukhin I. Attention Is All You Need // Advances in Neural Information Processing Systems. — 2017. — URL: <https://www.semanticscholar.org/paper/204e3073870fae3d05bcb2f6a8e263d9b72e776>.
2. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // NAACL-HLT. — 2019. — P. 4171–4186. — URL: <https://aclanthology.org/N19-1423>.
3. Liu Y., Ott M., Goyal N., Du J., Joshi M., Chen D., Levy O., Lewis M., Zettlemoyer L., Stoyanov V. RoBERTa: A Robustly Optimized BERT Pretraining Approach. — 2019. — URL: <https://www.semanticscholar.org/paper/077f8329a7b6fa3b7c877a57b81eb6c18b5f87de>.
4. Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // EMNLP-IJCNLP. — 2019. — P. 3982–3992. — URL: <https://aclanthology.org/D19-1410>.
5. Kuratov Y., Arkhipov M. Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language. — 2019. — URL: <https://arxiv.org/abs/1905.07213>.
6. Malykh V., et al. A Family of Pretrained Transformer Language Models for Russian. — 2023. — URL: <https://arxiv.org/abs/2309.10931>.
7. Beltagy I., Peters M.E., Cohan A. Longformer: The Long-Document Transformer. — 2020. — URL: <https://www.semanticscholar.org/paper/925ad2897d1b5decbea320d07e99afa9110e09b2>.
8. Wei J., Zou K. EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks // EMNLP-IJCNLP. — 2019. — P. 6382–6388. — URL: <https://aclanthology.org/D19-1670>.
9. Karimi A., Rossi L., Prati A. AEDA: An Easier Data Augmentation Technique for Text Classification // Findings of EMNLP. — 2021. — P. 2748–2754. — URL: <https://aclanthology.org/2021.findings-emnlp.234>.
10. Ciolino M., Noever D., Kalin J. Back Translation Survey for Improving Text Augmentation. — 2021. — URL: <https://www.semanticscholar.org/paper/34e6f0b17a2d413a68195692d3e35490a4e8a455>.
11. Jiang Z., Gao B., He Y., Han Y., Doyle P., Zhu Q. Text Classification Using Novel Term Weighting Scheme-Based Improved TF-IDF for Internet Media Reports // Mathematical Problems in Engineering. — 2021. — URL: <https://www.hindawi.com/journals/mpe/2021/6619088/>.
12. Watanangura P., Vanichrudee S., Minter O., Sringamdee T., Thanngam N., Siriborvornratanakul T. A Comparative Survey of Text Summarization Techniques // SN Computer Science. — 2023. — URL: <https://link.springer.com/10.1007/s42979-023-02343-6>.
13. Myla S.D., Saini R., Kapoor N. Auto Text Summarization in Natural Language Processing: Review // IDCIoT. — 2024. — URL: <https://ieeexplore.ieee.org/document/10467376/>.
14. Taskiran S.F., Turkoglu B., Kaya E., Aşuroğlu T. A comprehensive evaluation of oversampling techniques for enhancing text classification performance // Scientific Reports. — 2025. — URL: <https://www.nature.com/articles/s41598-025-05791-7>.
15. Hinojosa Lee M.C., Braet J., Springael J. Performance Metrics for Multilabel Emotion Classification: Comparing Micro, Macro, and Weighted F1-Scores // Applied Sciences. — 2024. — URL: <https://www.mdpi.com/2076-3417/14/21/9863>.

Книги и учебные издания:

1. Грон А. Машинное обучение. Наука и искусство построения алгоритмов, которые извлекают знания из данных. — СПб.: Питер, 2020. — 400 с.
2. Жуков Л.А. Машинное обучение и анализ данных. — М.: МФТИ, 2019. — 520 с.
3. Jurafsky D., Martin J.H. Speech and Language Processing. 3rd ed. — Draft. — 2023. — URL: <https://web.stanford.edu/~jurafsky/slp3/>.
4. Goldberg Y. Neural Network Methods for Natural Language Processing. — San Rafael: Morgan & Claypool, 2017. — 310 p.

Электронные ресурсы и документация:

1. DeepPavlov/rubert-base-cased: model card [Электронный ресурс]. — URL: <https://huggingface.co/DeepPavlov/rubert-base-cased> (дата обращения: 17.05.2026).
2. DeepPavlov/rubert-base-cased-sentence: model card [Электронный ресурс]. — URL: <https://huggingface.co/DeepPavlov/rubert-base-cased-sentence> (дата обращения: 17.05.2026).
3. ai-forever/ruRoberta-large: model card [Электронный ресурс]. — URL: <https://huggingface.co/ai-forever/ruRoberta-large> (дата обращения: 17.05.2026).
4. BERT in DeepPavlov documentation [Электронный ресурс]. — URL: <https://docs.deeppavlov.ai/en/master/features/models/bert.html> (дата обращения: 17.05.2026).
5. scikit-learn: TfidfVectorizer documentation [Электронный ресурс]. — URL: https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html (дата обращения: 17.05.2026).
6. scikit-learn: LinearSVC documentation [Электронный ресурс]. — URL: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html> (дата обращения: 17.05.2026).
7. scikit-learn: LogisticRegression documentation [Электронный ресурс]. — URL: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html (дата обращения: 17.05.2026).

Нормативные документы:

1. ГОСТ 7.32—2017. Система стандартов по информации, библиотечному и издательскому делу. Отчёт о научно-исследовательской работе. Структура и правила оформления. — М.: Стандартинформ, 2018. — 24 с.
2. ГОСТ Р 7.0.5—2008. Система стандартов по информации, библиотечному и издательскому делу. Библиографическая ссылка. Общие требования и правила составления. — М.: Стандартинформ, 2008. — 18 с.
3. ГОСТ 7.1—2003. Система стандартов по информации, библиотечному и издательскому делу. Библиографическая запись. Библиографическое описание. Общие требования и правила составления. — М.: Стандартинформ, 2003. — 47 с.