

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ
«МИФИ»

ИНСТИТУТ ИНТЕЛЛЕКТУАЛЬНЫХ КИБЕНЕТИЧЕСИКХ СИСТЕМ

КАФЕДРА «МАШИННОЕ ОБУЧЕНИЕ»

На правах рукописи

УДК _____

Пападык Всеволод Дмитриевич

**«Построение и применение композитных векторных представлений
текста для многоклассовой классификации текстов»**

Выпускная квалификационная работа магистра

Направление подготовки 01.04.02
«Прикладная математика и информатика»

Выпускная
квалификационная работа
защищена

«__»_____ 20
26 г.

Оценка

Секретарь ГЭК

г. Москва
2026

РЕФЕРАТ

КОМПОЗИТНЫЕ ВЕКТОРНЫЕ ПРЕДСТАВЛЕНИЯ, МНОГОКЛАССОВАЯ КЛАССИФИКАЦИЯ ТЕКСТОВ, АУГМЕНТАЦИЯ ДАННЫХ, TF-IDF, RUBERT

Объектом исследования являются методы автоматической многоклассовой классификации текстов в условиях ограниченного и несбалансированного корпоративного датасета.

Целью работы является исследование и реализация различных методов построения векторных представлений текста, включая подготовку к использованию композитных эмбедингов, и оценка их влияния на качество многоклассовой классификации с учётом совместной предобработки и аугментации данных.

В процессе работы проведён разведочный анализ исходных данных, выявлены структура и дисбаланс классов, разработаны и реализованы процедуры предобработки и очистки текстов. Реализованы два сценария текстовой аугментации для малочисленных классов: перефразирование и обратный перевод, позволяющие выровнять распределение классов и увеличить вариативность формулировок.

Построены и исследованы модели классификации на основе классического пайплайна TF-IDF + LinearSVC и нейросетевой модели ruBERT, обученные на исходном и аугментированных наборах данных. Выполнено сравнение моделей по набору метрик (accuracy, balanced accuracy, макро- и взвешенная F1-мера), а также проведён анализ ошибок и трудных классов. На основе полученных результатов сформулированы подходы к дальнейшему построению композитных векторных представлений текстов для улучшения качества классификации.

Основные характеристики разработанного прототипа включают модульную архитектуру пайплайна (предобработка, аугментация, построение эмбедингов, обучение и оценка моделей), возможность сравнения классических и нейросетевых подходов и готовность к расширению за счёт внедрения композитных эмбедингов.

Степень внедрения результатов работы определяется возможностью адаптации разработанного прототипа к задачам автоматической классификации корпоративных текстов, в частности маршрутизации обращений и категоризации внутренних документов. Полученные наработки и программная реализация могут быть использованы в качестве основы для последующей интеграции в промышленные системы анализа текстовых данных.

Ключевые слова: МНОГОКЛАССОВАЯ КЛАССИФИКАЦИЯ, ТЕКСТОВЫЕ ЭМБЕДДИНГИ, КОМПОЗИТНЫЕ ПРЕДСТАВЛЕНИЯ, АУГМЕНТАЦИЯ ТЕКСТОВ, TF-IDF, RUBERT, НЕЙРОСЕТЕВЫЕ МОДЕЛИ.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	5
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	7
ВВЕДЕНИЕ	8
1 Обзор предметной области	10
1.1 Многоклассовая классификация текстов и её приложения.....	10
1.2 Векторные представления текста: от Bag-of-Words до контекстных эмбедингов	10
1.3 Проблемы разреженности, дисбаланса классов и качества представлений	10
1.4 Идея композитных векторных представлений текста.....	11
2 Проектирование решения	12
2.1 Постановка задачи и требования к системе	12
2.2 Характеристика исходного датасета и постановка экспериментов	12
Для оценки влияния различных методов обработки и представления текста было задумано несколько серий экспериментов:.....	12
2.3 Общая архитектура пайплайна обработки и классификации текста	13
С учётом поставленных требований была спроектирована модульная архитектура решения, включающая следующие основные этапы:	13
2.4 Выбор базового классического подхода (TF-IDF + линейный классификатор)	13
2.5 Выбор нейросетевой модели (ruBERT для классификации текстов)	13
3 Разведочный анализ и предобработка данных	15
3.1 Структура датасета и распределение классов.....	15
Рисунок 3.1 — Распределение числа текстов по классам (top-30)	16
3.2 Анализ длины текстов и качества исходных данных.....	16
Рисунок 3.3 — Распределение длины текстов по числу символов.....	17
3.3 Обнаружение дубликатов и аномальных объектов	18
3.4 Правила очистки и нормализации текстов.....	18
3.5 Итоговое состояние данных после предобработки	18
4 Аугментация данных и обогащение выборки.....	19
4.1 Мотивация аугментации при дисбалансе классов.....	19
4.2 Сценарий аугментации с использованием перефразирования.....	19
4.3 Сценарий аугментации методом обратного перевода.....	19
4.4 Схема доведения редких классов до порогового размера выборки.....	20
4.5 Анализ влияния аугментации на распределение данных	20
5 Реализация моделей классификации	25
5.1 Базовый классический пайплайн на TF-IDF и LinearSVC	25
5.2 Настройка гиперпараметров и схема обучения базовой модели	25
5.3 Нейросетевая модель на основе ruBERT	25
5.4 Организация обучения ruBERT: датасеты, разбиение, метрики.....	26

5.5 Итоговая конфигурация программного прототипа	26
6 Тестирование и исследование результатов	27
6.1 Эксперименты с базовой моделью до и после аугментации	27
6.2 Эксперименты с ruBERT и влияние аугментации	27
6.3 Сравнительный анализ метрик качества моделей	28
6.4 Анализ ошибок и трудных классов	28
6.5 Выводы по текущей версии решения и направления развития (композитные эмбединги)	28
ЗАКЛЮЧЕНИЕ	29
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ Статья в периодических изданиях и сборниках статей:	31

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчете применяют следующие термины с соответствующими определениями:

Многоклассовая классификация текста	— процесс отнесения текстового объекта к одному из заранее определённых классов из конечного множества категорий
Векторное представление текста (эмбединг текста)	— численное представление текста в виде вектора фиксированной длины, формируемое таким образом, чтобы сохранять семантические и синтаксические свойства исходного текста
Композитное векторное представление текста	— векторное представление, полученное путём объединения двух и более базовых эмбедингов, построенных различными методами (например, TF-IDF и контекстные эмбединги), для более полного отражения свойств текста
Текстовая аугментация	— совокупность методов искусственного увеличения объёма обучающей выборки за счёт генерации новых текстов на основе исходных с сохранением их семантики (перефразирование, обратный перевод и другие методы)
Перефразирование текста	— метод текстовой аугментации, при котором исходный текст преобразуется в новый текст, близкий по смыслу, но отличающийся лексически и/или синтаксически
Обратный перевод (back-translation)	— метод текстовой аугментации, при котором исходный текст переводится на другой язык, а затем обратно, в результате чего получается новый текст, сохраняющий исходный смысл при изменённой формулировке
Базовая модель классификации	— модель, реализующая простой или широко используемый подход (например, TF-IDF + линейный классификатор), служащая отправной точкой для сравнения с более сложными решениями
Нейросетевая модель классификации текста	— модель классификации, основанная на искусственных нейронных сетях (в том числе трансформерных архитектурах), использующая распределённые векторные представления текста

Корпоративный
датасет текстов

— набор текстовых данных,
сформированный в рамках деятельности
организации и отражающий её реальные
процессы (обращения, документы, описания
инцидентов и т.п.)

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчете применяют следующие сокращения и обозначения:

BERT	—	Bidirectional Encoder Representations from Transformers, двунаправленная языковая модель на основе архитектуры трансформеров
ruBERT	—	русскоязычная модификация модели BERT, предобученная на русскоязычных текстовых коллекциях
TF-IDF	—	Term Frequency – Inverse Document Frequency, взвешенная частотная модель представления текста, учитывающая частоту термина в документе и редкость термина в коллекции
SVM	—	Support Vector Machine, метод опорных векторов, класс алгоритмов машинного обучения для решения задач классификации и регрессии
F1-мера (F1)	—	гармоническое среднее между точностью (precision) и полнотой (recall), используемое для оценки качества классификации
Balanced F1(macro-F1)	—	сбалансированная F1-мера при мультиклассовой классификации: вычисляется F1-мера отдельно для каждого класса и затем берётся их среднее арифметическое, так что все классы учитываются равноправно, независимо от дисбаланса по количеству объектов
Accuracy	—	доля правильно классифицированных объектов в общей выборке
Balanced accuracy	—	сбалансированная точность, среднее арифметическое по классам от доли правильно классифицированных объектов каждого класса
GPU	—	Graphics Processing Unit, графический процессор, используемый для ускорения вычислений при обучении нейросетевых моделей
EDA	—	Exploratory Data Analysis, первичный исследовательский анализ данных

ВВЕДЕНИЕ

В условиях стремительного роста объёмов текстовой информации задачи автоматической классификации документов и сообщений становятся ключевыми для современных информационных систем. Они лежат в основе тематической маршрутизации обращений, аналитики пользовательской активности, мониторинга инцидентов и поддержки принятия управленческих решений. При этом на практике такие задачи часто имеют многоклассовый характер и сопровождаются выраженным дисбалансом классов, что существенно осложняет построение надёжных и устойчивых моделей.

Традиционные подходы к представлению текста, основанные на мешке слов и TF-IDF, позволяют эффективно использовать линейные классификаторы, но имеют ряд ограничений. Они плохо учитывают семантическую близость слов и чувствительны к вариативности формулировок, что приводит к потере части смысловой информации. Появление распределённых векторных представлений, а затем и контекстных эмбедингов на основе трансформеров (таких как BERT), существенно повысило качество решения задач обработки естественного языка. Однако даже в этих условиях итоговая эффективность классификации в значительной степени определяется тем, насколько удачно выбраны и скомбинированы представления текста, а также тем, как учтён дисбаланс и ограниченность данных.

Особый интерес представляет подход, при котором для одного и того же текста формируются несколько векторных представлений, полученных различными методами, а затем объединяются в композитный эмбединг. Такой подход позволяет использовать сильные стороны каждого из базовых представлений: устойчивость TF-IDF к редким словам и артефактам, способность контекстных моделей учитывать окружение слова, а также дополнительные признаки, отражающие структуру и формальные особенности текста. В сочетании с целевой аугментацией данных для редких классов это открывает возможности для улучшения качества многоклассовой классификации без радикального увеличения объёма исходной обучающей выборки.

Настоящая работа посвящена исследованию методов построения и применения композитных векторных представлений текста для задач многоклассовой классификации на примере реального корпоративного датасета с выраженным дисбалансом классов. В рамках работы проводится разведочный анализ данных, реализуются сценарии текстовой аугментации (перефразирование и обратный перевод), строятся базовые и нейросетевые модели классификации, а также закладывается основа для формирования сложных эмбедингов на основе комбинирования различных представлений.

Цель работы заключается в исследовании и реализации методов построения векторных представлений текста, в том числе композитных эмбедингов, и оценке их влияния на качество многоклассовой классификации с учётом совместной предобработки и аугментации данных.

Для достижения поставленной цели в работе решаются следующие задачи:

- 1) провести разведочный анализ исходного датасета, оценить структуру и дисбаланс классов, а также качество текстов;
- 2) разработать и реализовать процедуры предобработки и очистки текстов, учитывающие специфику предметной области;
- 3) исследовать и реализовать методы текстовой аугментации (перефразирование и обратный перевод) для обогащения малочисленных классов;
- 4) построить базовый классический пайплайн классификации на основе TF-IDF и линейного классификатора и оценить его качество;
- 5) реализовать и обучить нейросетевую модель на основе ruBERT для многоклассовой классификации текстов;
- 6) сравнить качество моделей на исходном и аугментированных наборах данных, проанализировать влияние аугментации на редкие классы;
- 7) сформулировать требования и подходы к построению композитных векторных представлений текста для дальнейших экспериментов.

Объектом исследования в работе является процесс автоматической многоклассовой классификации текстов в условиях ограниченного и несбалансированного датасета.

Предметом исследования являются методы построения векторных представлений текста и подходы к их комбинированию в композитные эмбединги, а также их влияние на качество классификации при использовании классических и нейросетевых моделей.

Теоретическая значимость работы состоит в систематизации и уточнении представлений о влиянии разных типов векторных представлений и приёмов аугментации на качество многоклассовой текстовой классификации. Рассматривается связка: предобработка, аугментация, выбор модели и стратегия формирования эмбедингов, что позволяет уточнить роли каждого компонента в общей архитектуре решения.

Практическая значимость работы выражается в разработке воспроизводимого программного прототипа, включающего полный пайплайн обработки данных: от предобработки и аугментации до обучения и оценки моделей классификации. Полученные результаты и рекомендации могут быть использованы при разработке систем маршрутизации обращений, автоматической категоризации внутренних документов и других прикладных задач анализа текстовых данных в корпоративной среде

1 Обзор предметной области

1.1 Многоклассовая классификация текстов и её приложения

Многоклассовая классификация текста заключается в отнесении каждого текстового объекта к одной из заранее заданных категорий из конечного множества. В прикладных корпоративных системах такие категории могут соответствовать тематике документов, типам обращений пользователей, видам инцидентов информационной безопасности или организационным подразделениям, ответственным за обработку сообщения. Автоматизация этого процесса позволяет разгрузить экспертов, уменьшить время реакции на события и повысить устойчивость процедур обработки информации.

Особенностью многоклассовых задач является необходимость одновременно различать большое число классов, часто с пересекающейся семантикой. К этому добавляются практические сложности: неравномерное распределение примеров по классам, наличие редких, но критически важных категорий, а также вариативность формулировок в рамках одного и того же типа сообщений. В совокупности это предъявляет повышенные требования к выбору представления текста и к архитектуре модели классификации.

1.2 Векторные представления текста: от Bag-of-Words до контекстных эмбеддингов

Для применения алгоритмов машинного обучения текст должен быть преобразован в численное представление — вектор признаков фиксированной длины. Самые ранние подходы опирались на модели one-hot и Bag-of-Words, в которых каждый текст описывается вектором, отражающим частоты или наличие слов из словаря. Расширение этой идеи — TF-IDF — позволяет взвешивать слова с учётом их частоты в документе и редкости в коллекции, снижая влияние часто встречающихся, но малоинформативных терминов.

Однако такие представления не учитывают порядок слов и семантическую близость, а также страдают от разреженности при больших словарях. Для преодоления этих ограничений были предложены плотные распределённые представления слов (word embeddings), получаемые, например, методами Word2Vec, GloVe и FastText, в которых каждая лексема отображается в вектор невысокой размерности, обученный на больших корпусах. Последующим шагом стало появление контекстных эмбеддингов, в том числе на основе архитектуры BERT, которые формируют представление токена или целого текста с учётом контекста, что позволяет различать многозначные слова и тонкие смысловые нюансы.

1.3 Проблемы разреженности, дисбаланса классов и качества представлений

Несмотря на прогресс в области эмбеддингов, на практике сохраняется ряд проблем, влияющих на качество многоклассовой классификации. Во-первых, разреженность и высокое измерение признакового пространства в классических моделях (TF-IDF) повышают риск переобучения и требуют осторожного выбора регуляризации и алгоритма классификации. Во-вторых, дисбаланс классов приводит к тому, что стандартные метрики, такие как ассигасу, могут существенно переоценивать качество на редких классах, а обучение моделей склонно игнорировать малочисленные категории.

В таких условиях особую роль играют макро-усреднённые метрики (F1-macro, balanced ассигасу) и методы компенсации дисбаланса: взвешивание классов, переобучение

на синтетических или аугментированных примерах и специализированные стратегии формирования батчей. Наконец, даже контекстные модели не всегда оптимально отражают специфичные для конкретной предметной области различия между классами, особенно если исходный датасет невелик. Это мотивирует исследование комбинированных подходов, которые объединяют преимущества различных типов векторных представлений и дополнительно используют аугментацию данных.

1.4 Идея композитных векторных представлений текста

Под композитным векторным представлением текста в данной работе понимается вектор, сформированный путём объединения нескольких базовых эмбеддингов, полученных различными методами. В простейшем случае это может быть конкатенация TF-IDF-вектора и плотного контекстного представления, либо взвешенная сумма нескольких эмбеддингов, отражающих разные аспекты текста. Цель такого объединения — использовать сильные стороны каждого из компонентов: статистическую устойчивость классических признаков и богатую семантику нейросетевых моделей.

Подобные композитные представления позволяют гибко настраивать вклад различных источников информации и адаптировать модель под конкретную задачу и датасет. В контексте многоклассовой классификации корпоративных текстов это открывает возможность лучше различать близкие по смыслу категории, учитывать специфические термины и формальные признаки, а также более эффективно использовать результаты аугментации данных. Именно изучению таких подходов в сочетании с аугментацией и посвящена основная часть выполненной работы.

2 Проектирование решения

2.1 Постановка задачи и требования к системе

В рамках работы рассматривается задача автоматической многоклассовой классификации кратких текстовых описаний, соответствующих различным организационным блокам и подразделениям крупной компании. Для каждого текста требуется определить один класс из фиксированного множества категорий, характеризующих принадлежность обращения или записи к определённой тематике или зоне ответственности. Таким образом, система классификации должна обеспечивать устойчивое качество предсказаний при большом количестве классов и значительном дисбалансе между ними.

К ключевым требованиям к разрабатываемому решению относятся:

- способность корректно обрабатывать короткие и неоднородные по стилю тексты;
- устойчивость к дисбалансу классов и наличие механизмов улучшения качества на редких категориях;
- возможность прозрачного сравнения классического и нейросетевого подходов к классификации;
- расширяемость архитектуры для последующего внедрения композитных эмбедингов и дополнительных методов аугментации.

2.2 Характеристика исходного датасета и постановка экспериментов

Исходный датасет представляет собой выборку из 1994 текстовых записей, каждая из которых снабжена меткой класса, отражающей принадлежность к одному из нескольких десятков организационных подразделений. Анализ показал, что распределение по классам существенно несбалансировано: присутствует небольшое число крупных классов и длинный «хвост» редких категорий, некоторые из которых представлены порядка 30–40 примерами и менее. Тексты на русском языке, имеют длину от нескольких слов до нескольких предложений и содержат элементы делового и технического стиля.

Для оценки влияния различных методов обработки и представления текста было задумано несколько серий экспериментов:

- обучение и тестирование моделей на исходном датасете без аугментации;
- эксперименты на наборах, расширенных с помощью перефразирования;
- эксперименты на наборах, расширенных методом обратного перевода;
- эксперименты на объединённом аугментированном датасете.
- во всех сериях используется единая схема разбиения данных на обучающую и валидационную выборки, что обеспечивает сопоставимость результатов.

2.3 Общая архитектура пайплайна обработки и классификации текста

С учётом поставленных требований была спроектирована модульная архитектура решения, включающая следующие основные этапы:

- 1) загрузка и разведочный анализ исходных данных;
- 2) предобработка и очистка текстов;
- 3) аугментация данных для редких классов (перефразирование, обратный перевод);
- 4) построение векторных представлений текста (классические и нейросетевые эмбединги);
- 5) обучение и оценка моделей классификации;
- 6) анализ результатов и ошибок.

Каждый этап реализован в виде отдельного блока (ноутбука или скрипта), что позволяет гибко модифицировать и переиспользовать элементы пайплайна. Такая структура позволяет, с одной стороны, сравнивать различные комбинации методов предобработки, аугментации и векторизации, а с другой — в дальнейшем без существенных изменений встраивать новые компоненты, включая композитные эмбединги и дополнительные модели.

2.4 Выбор базового классического подхода (TF-IDF + линейный классификатор)

В качестве базовой точки отсчёта выбран классический подход, основанный на TF-IDF-представлении текста и линейном классификаторе Support Vector Machine. Такой выбор обусловлен тем, что TF-IDF остаётся стандартом де-факто для многих практических задач текстовой классификации, обеспечивая понятные и интерпретируемые признаки. Линейные модели, в свою очередь, хорошо масштабируются на высокоразмерные разреженные признаки и позволяют эффективно использовать регуляризацию.

Реализованный базовый пайплайн сочетает слово-ориентированный TF-IDF по униграммам и биграммам с символьными n-граммами, объединёнными с помощью FeatureUnion, и линейный классификатор LinearSVC с балансировкой классов. Этот подход служит нижней оценкой качества и даёт возможность количественно оценить вклад аугментации и перехода к более сложным векторным представлениям на основе нейросетей.

2.5 Выбор нейросетевой модели (ruBERT для классификации текстов)

В качестве основной нейросетевой модели был выбран предобученный русскоязычный трансформер DeepPavlov/rubert-base-cased, зарекомендовавший себя как эффективное средство для решения широкого спектра задач обработки русского текста. Модель BERT позволяет формировать контекстные эмбединги, учитывающие окружение токенов и тонкие смысловые различия, что особенно важно для задач с близкими по формулировкам, но различными по смыслу классами.

Дообучение модели выполняется в режиме классификации последовательностей: на выходе используется представление CLS-токена или агрегированное представление последовательности, проходящее через линейный слой с числом выходов, равным числу классов. Переход к ruBERT позволяет исследовать, насколько контекстные эмбединги, в

сочетании с аугментацией данных, улучшат качество многоклассовой классификации по сравнению с классическим TF-IDF-подходом.

3 Разведочный анализ и предобработка данных

3.1 Структура датасета и распределение классов

Исходный датасет представляет собой набор коротких текстовых описаний, каждому из которых поставлена в соответствие одна категориальная метка из множества организационных блоков и подразделений компании. Тексты представлены на русском языке, содержат элементы деловой лексики и специфические наименования структурных единиц и процессов. Общее число объектов после первичной загрузки и очистки составляет 1994 записи, каждая запись содержит текст и метку класса.

Классовая структура датасета существенно несбалансирована: часть классов представлена сотнями примеров, тогда как другие имеют менее 40 наблюдений, на рисунке 3.1 представлена столбчатая диаграмма. Анализ распределения показал, что в исходных данных присутствует 36 различных классов, при этом «хвост» редких категорий даёт заметный вклад в общую сложность задачи. Такая ситуация типична для прикладных задач классификации обращений и внутренних документов, где некоторые типы событий встречаются значительно реже, но их корректное распознавание важно для бизнеса.

Таблица 3.1 — Распределение классов в исходном датасете

label	count
Блок технического директора	249
Блок директора по мощностям	243
Блок директора по строительству	166
Управление по проектным работам	136
Блок заместителя генерального директора по безопасности	125
Генеральный директор	103
Проект "Нефтяные краюшки"	79
Блок деректора по газу	73
Блок заместителя генерального директора по закупкам	67
Блок заместителя генерального директора по организационным вопросам	58
Проект сервиса скважин	47
Блок директора по проектированию	44
Проект "Новая нефть"	38
Проект "Северная деревня"	36
Блок операционного директора	33
Блок директора по газовым проектам	31
Блок финансового директора	26
Блок заместителя генерального директора по защите	26
Блок директора по портфелю	24
Управление землеустроительных работ	23
Проект "Трубопроводный транспорт Главного НГКМ"	20
Блок директора по персоналу	18
Проект «Обустройство объектов Новой нефти»	18
Проект "Восточный"	18
Блок заместителя генерального директора по имуществу	17

Проект "Южный"	12
Блок бизнес-директора	8
Проект «Обустройство Интересного лицензионного участка»	7
Управление коммуникаций	7
Проект "Обустройство площадных объектов НГКМ Поменбше"	6
Блок исполнительного директора по реализации проекта "Большое месторождение"	5
Проект «Обустройство объектов Новейшей нейти»	3
Подразделение по информационным технологиям	2
Имущественные вопросы	2
Проект «Трубопроводный транспорт Ещё одного НГКМ»	2
Блок заместителя генерального директора по строительству	2




Рисунок 3.1 — Распределение числа текстов по классам (top-30)

3.2 Анализ длины текстов и качества исходных данных

На втором этапе разведочного анализа были исследованы статистики длины текстов в символах и словах, **их визуализация представлена на рисунках 3.2 и 3.3**. Для каждого объекта вычислялось число токенов (слов) после простой токенизации, что позволило оценить типичную длину записей и выделить потенциальные выбросы. Большинство текстов укладывается в короткий или средний диапазон длины, что характеризует задачу как классификацию относительно небольших фраз и описаний, а не длинных документов.

Дополнительно были выявлены единичные записи с аномально малой длиной (1–2 слова) либо, наоборот, содержащие чрезмерно длинные и составные описания. Такие объекты требуют осторожного обращения: слишком короткие тексты могут нести недостаточно информации для уверенной классификации, а слишком длинные — оказываться смесью нескольких тематик. На основании анализа было принято решение не вводить жёсткую фильтрацию по длине, но учитывать эти особенности при интерпретации результатов и выборе максимальной длины последовательности для нейросетевой модели.

Таблица 3.2 — Описательные статистики длины текстов

	Количество СИМВОЛОВ	Длина СЛОВ
count	1774.0	1774.0
mean	2923.6	315.52
std	7091.16	701.42
min	49.0	8.0
25%	923.0	106.25
50%	1277.5	149.0
75%	1921.5	230.0
max	69225.0	7455.0




Рисунок 3.2 — Распределение длины текстов по числу слов



Рисунок 3.3 — Распределение длины текстов по числу символов

3.3 Обнаружение дубликатов и аномальных объектов

Отдельным шагом выполнялся поиск дублирующихся записей по тексту. Для этого использовалась группировка по строковому полю текста с подсчётом числа вхождений, что позволило выявить тексты, встречающиеся более одного раза. Наличие дубликатов в обучающей и тестовой выборках может приводить к завышению оценок качества и снижению обобщающей способности модели.

В ходе анализа были обнаружены повторяющиеся описания, относящиеся к одним и тем же классам, а также небольшое число подозрительных объектов, где совпадающий текст был размечен разными метками. Для точности экспериментов явные технические дубликаты в пределах одной выборки были удалены, а случаи конфликтующей разметки проанализированы вручную и либо удалены, либо приведены к согласованным меткам. Такой шаг уменьшает риск «подглядывания» модели в тест и повышает достоверность последующих сравнений методов.

Точных дубликатов текстов до очистки: 10, после: 5.

3.4 Правила очистки и нормализации текстов

Исходные тексты содержали различные артефакты: повторяющиеся пробелы, служебные символы, фрагменты технических обозначений, которые не несут семантической нагрузки для классификации. На этапе предобработки были реализованы процедуры нормализации регистра, удаления лишних пробельных символов, очистки от «шумовых» знаков и приведения текста к унифицированному виду. Это позволило уменьшить количество уникальных токенов и стабилизировать вход для последующих моделей векторизации.

При этом предобработка выполнялась аккуратно, без агрессивного стемминга или лемматизации, чтобы не разрушить специфические доменные термины и названия подразделений. В частности, сохранялись ключевые аббревиатуры и буквенно-цифровые обозначения, потенциально влияющие на класс объекта. Такой компромиссный подход обеспечивает баланс между снижением шума и сохранением важной предметной информации.

3.5 Итоговое состояние данных после предобработки

После применения всех описанных процедур (удаление пустых и некорректных записей, обработка дубликатов, очистка текста) была сформирована итоговая версия датасета, использованная в дальнейших экспериментах. Число объектов в ней составило 1994 строки, при этом каждая запись содержит ровно один нормализованный текст и одну целевую метку. Классовая структура осталась несбалансированной, что впоследствии компенсируется с помощью аугментации и выбора соответствующих моделей и метрик.

Итоговое распределение классов демонстрирует характерную «длинную» структуру: небольшое число крупных классов и значительное количество малочисленных категорий. Эти особенности определяют требования к последующим шагам: выбор устойчивых к дисбалансу алгоритмов, использование аугментации для редких классов и применение метрик, учитывающих неравномерность распределения (например, F1-меры и balanced accuracy).

4 Аугментация данных и обогащение выборки

4.1 Мотивация аугментации при дисбалансе классов

Анализ исходного датасета показал выраженный дисбаланс классов: часть категорий представлена десятками и сотнями примеров, тогда как наименее распространённые классы содержат около 30–40 текстов и меньше. В таких условиях классические модели и нейросетевые классификаторы склонны переобучаться на доминирующие классы и игнорировать редкие категории, что приводит к низким значениям F1-меры и balanced accuracy на «хвосте» распределения.

Для уменьшения этого эффекта было принято решение использовать текстовую аугментацию, направленную на обогащение именно малочисленных классов. В отличие от простого масштабирования выборки или взвешивания классов в функции потерь, аугментация позволяет дополнительно расширить вариативность формулировок, сохраняя при этом исходную семантику. Это особенно важно в задачах, где небольшие стилистические и формальные изменения текста не меняют принадлежность к классу, но дают модели больше примеров для обучения.

4.2 Сценарий аугментации с использованием перефразирования

Первый трек аугментации основан на генерации перефразированных версий исходных текстов с помощью предобученной модели перефразирования для русского языка. Для каждого объекта из малочисленных классов формируется несколько кандидатов-перефразов, которые затем фильтруются с использованием меры семантической близости. В качестве критерия отсева используются векторные представления предложений и косинусное сходство между исходным текстом и кандидатом: тексты с недостаточной семантической близостью отбрасываются.

Процесс аугментации организован итеративно: для каждого целевого класса генерируются перефразы исходных текстов до тех пор, пока число примеров в классе не достигнет заданного минимального порога. При этом ограничивается и максимальное число перефраз для одного исходного текста, чтобы избежать ситуаций, когда класс заполняется большим количеством почти идентичных формулировок. Итогом работы данного трека становится расширенный датасет, в котором малочисленные классы дополнены синтетическими, но семантически согласованными примерами.

4.3 Сценарий аугментации методом обратного перевода

Второй трек аугментации использует метод обратного перевода (back-translation), который заключается в двойном переводе текста через промежуточный язык. На первом шаге исходные русскоязычные тексты переводятся на английский язык, а затем полученный результат переводится обратно на русский. Благодаря особенностям машинного перевода итоговый текст, как правило, сохраняет исходный смысл, но отличается лексически и синтаксически, что делает его полезным аугментированным примером.

Для контроля качества аугментированных текстов по back-translation также применяются проверки семантического сходства и дополнительные эвристики по длине и структуре. Кандидаты с чрезмерными искажениями (например, появлением нерелевантных сущностей или сильным сокращением текста) исключаются из итогового

набора. Аналогично перефразированию, процедура обратного перевода нацелена преимущественно на малочисленные классы и выполняется до достижения порогового числа примеров в каждом таком классе.

4.4 Схема доведения редких классов до порогового размера выборки

Оба трека аугментации — перефразирование и обратный перевод — используются совместно для выравнивания распределения классов. Для каждого класса заранее задаётся целевое минимальное число примеров (например, 30 объектов), после чего последовательно применяются перефразирование и back-translation к исходным текстам этого класса. Количество сгенерированных примеров контролируется так, чтобы итоговое число объектов незначительно превышало, но не сильно превосходило заданный порог, сохраняя разумный баланс между классами.

Результатом данного этапа является несколько вариантов обучающих выборок: исходная (без аугментации), расширенные наборы для каждого трека отдельно и объединённый датасет, включающий оригинальные и аугментированные тексты. Эти наборы далее используются для обучения и сравнения различных моделей классификации, что позволяет оценить вклад каждого метода аугментации в итоговое качество.

4.5 Анализ влияния аугментации на распределение данных

После выполнения аугментации были повторно рассчитаны распределения классов и ключевые статистики датасета. Полученные результаты показывают существенное выравнивание «хвоста» распределения: большинство ранее малочисленных классов достигли заданного минимального размера, а дисперсия по числу объектов на класс заметно уменьшилась. Это создаёт более благоприятные условия для обучения как линейных моделей, так и нейросетевых классификаторов на основе ruBERT.

Визуальный анализ (гистограммы и долевые диаграммы до и после аугментации), представленные на рисунке 4.1, дополнительно подтверждает, что новые примеры смещают распределение в сторону более равномерного, но при этом не приводят к избыточному доминированию синтетических данных. Наличие нескольких вариантов аугментированных датасетов позволяет в дальнейшей части работы сравнить влияние перефразирования и обратного перевода по отдельности, а также их совместное использование, на качество классификации.

Таблица 4.1 — Сводные характеристики датасетов

		n_s	n_	min_p	max_p	mean_
dataset	amples	classes	er_class	er_class	per_class	
train	9	141	36	1	202	39.42
train_paraphrase	5	184	36	30	202	51.25
train_backward_translate	6	181	36	1	202	50.44
train_augmented	4	199	36	30	202	55.39

Таблица 4.2 — Распределение классов по трекам аугментации

label	in	tra rase	train_paragraph late	train_backtrans
Блок бизнес-директора		6	30	30
Блок деректора по газу		59	59	59
Блок директора по газовым проектам		24	30	30
Блок директора по мощностям	7	19	197	197
Блок директора по персоналу		14	30	30
Блок директора по портфелю		19	30	30
Блок директора по проектированию		35	35	35
Блок директора по строительству	5	13	135	135
Блок заместителя генерального директора по безопасности	1	10	101	101
Блок заместителя генерального директора по закупкам		54	54	54
Блок заместителя генерального директора по защите		20	30	30
Блок заместителя генерального директора по имуществу		13	30	30
Блок заместителя генерального директора по организационным вопросам		47	47	47
Блок заместителя генерального директора по строительству		1	30	30
Блок исполнительного директора по реализации проекта "Большое месторождение"		3	30	30
Блок операционного директора		26	30	30
Блок технического директора	2	20	202	202
Блок финансового директора		20	30	30
Генеральный директор		83	83	83
Имущественные вопросы		1	30	30
Подразделение по информационным технологиям		1	30	30
Проект "Восточный"		14	30	30

Проект "Нефтяные краюшки"	64	64	64
Проект "Новая нефть"	30	30	30
Проект "Обустройство площадных объектов НГКМ Поменбше"	4	30	30
Проект "Северная деревня"	29	30	30
Проект "Трубопроводный транспорт Главного НГКМ"	15	30	30
Проект "Южный"	9	30	30
Проект «Обустройство Интересного лицензионного участка»	5	30	30
Проект «Обустройство объектов Новейшей нейти»	2	30	30
Проект «Обустройство объектов Новой нефти»	14	30	30
Проект «Трубопроводный транспорт Ещё одного НГКМ»	1	30	1
Проект сервиса скважин	38	38	38
Управление землеустроительных работ	18	30	30
Управление коммуникаций	5	30	30
Управление по проектным работам	11 0	110	110

Таблица 4.3 — Распределение классов до и после аугментации

label	in	tra nted	train_augme
Блок бизнес-директора		6	36
Блок деректора по газу		59	59
Блок директора по газовым проектам		24	36
Блок директора по мощностям	7	19	197
Блок директора по персоналу		14	42
Блок директора по портфелю		19	41
Блок директора по проектированию		35	34
Блок директора по строительству	5	13	134
Блок заместителя генерального директора по безопасности	1	10	101
Блок заместителя генерального директора по закупкам		54	54
Блок заместителя генерального директора по защите		20	40

Блок заместителя генерального директора по имуществу	13	41
Блок заместителя генерального директора по организационным вопросам	47	47
Блок заместителя генерального директора по строительству	1	31
Блок исполнительного директора по реализации проекта "Большое месторождение"	3	31
Блок операционного директора	26	34
	20	
Блок технического директора	2	202
Блок финансового директора	20	40
Генеральный директор	83	83
Имущественные вопросы	1	31
Подразделение по информационным технологиям	1	31
Проект "Восточный"	14	43
Проект "Нефтяные краюшки"	64	64
Проект "Новая нефть"	30	30
Проект "Обустройство площадных объектов НГКМ Поменбше"	4	34
Проект "Северная деревня"	29	31
Проект "Трубопроводный транспорт Главного НГКМ"	15	43
Проект "Южный"	9	39
Проект «Обустройство Интересного лицензионного участка»	5	35
Проект «Обустройство объектов Новейшей нейти»	2	32
Проект «Обустройство объектов Новой нефти»	14	43
Проект «Трубопроводный транспорт Ещё одного НГКМ»	1	30
Проект сервиса скважин	38	38
Управление землеустроительных работ	18	42
Управление коммуникаций	5	35
	11	
Управление по проектным работам	0	110




Рисунок 4.1 — Распределение классов до и после аугментации (top-30)

5 Реализация моделей классификации

5.1 Базовый классический пайплайн на TF-IDF и LinearSVC

В качестве отправной точки для оценки сложности задачи и влияния аугментации был реализован базовый классический пайплайн на основе TF-IDF-признаков и линейного поддерживающего вектора (LinearSVC). Такой подход традиционно используется для текстовой классификации и обеспечивает хорошее качество при сравнительно низких вычислительных затратах.

В реализованном решении используется следующая схема представления текста: слова кодируются с помощью TF-IDF-векторайзера по униграммам и биграммam, дополнительно строится TF-IDF по символьным n-граммам (3–5 символов) с последующим объединением двух представлений через FeatureUnion. Это позволяет одновременно учитывать лексическую структуру текста и устойчиво обрабатывать вариации написания и орфографические отклонения. На полученных признаках обучается линейный классификатор LinearSVC с балансировкой классов за счёт параметра `class_weight="balanced"`.

5.2 Настройка гиперпараметров и схема обучения базовой модели

Обучение базовой модели проводится на одном из подготовленных обучающих датасетов (исходном или аугментированном), содержащем текстовые поля и метки классов. На этапе подготовки данных тексты приводятся к строковому типу, а метки — к строковым или категориальным значениям, что обеспечивает корректную работу векторизаторов и классификатора. Разделение на обучающую и тестовую выборки выполняется заранее, что позволяет использовать одну и ту же схему для сравнения различных вариантов моделей и датасетов.

Конфигурация TF-IDF-векторизаторов включает ограничение по минимальной и максимальной частоте для символьных n-грамм, а также использование стандартной токенизации для слов. Линейный классификатор LinearSVC обучается с параметрами по умолчанию, при этом ключевым элементом является включение балансировки классов, позволяющей частично компенсировать несбалансированное распределение целевых меток. По итогам обучения модель сохраняется на диск с помощью библиотеки `joblib`, что обеспечивает возможность дальнейшего использования и сравнения без повторного обучения.

5.3 Нейросетевая модель на основе ruBERT

Для повышения качества классификации и исследования влияния аугментации на современные контекстные представления текста была реализована нейросетевая модель на основе архитектуры BERT, а именно предобученного русскоязычного трансформера `DeepPavlov/rubert-base-cased`. Модель дообучается в режиме классификации последовательностей: поверх встроенного эмбедингового слоя и трансформерных блоков добавляется линейная классификационная «голова», прогнозирующая одну из целевых категорий.

Используется стандартный пайплайн библиотеки `Transformers`: токенизация текстов с помощью `AutoTokenizer`, приведение длины последовательностей к фиксированному максимуму (например, 256 токенов) с усечением и паддингом,

формирование наборов данных DatasetDict для обучения и валидации. Все метки классов кодируются целочисленными идентификаторами, а обратное отображение сохраняется в отдельный файл для последующей интерпретации результатов. Обучение модели выполняется на GPU, что существенно ускоряет процесс дообучения на специализированном датасете.

5.4 Организация обучения ruBERT: датасеты, разбиение, метрики

Для обеспечения сопоставимости экспериментов используется единая схема разбиения данных на обучающую и валидационную выборки, сохраняемая в отдельные CSV-файлы. Если файлы разбиений уже существуют, они переиспользуются в последующих запусках, что гарантирует воспроизводимость результатов при обучении на разных вариантах датасетов (с аугментацией и без неё). Токенизированные данные упаковываются в формат DatasetDict, а формат хранения устанавливается как тензорный, что позволяет непосредственно использовать их в тренировочном цикле.

Обучение модели организовано с помощью класса Trainer и настроек TrainingArguments, включающих стратегию валидации по эпохам, выбор лучшей модели по метрике F1-макро, ограничение числа сохраняемых чекпоинтов и использование смешанной точности при наличии GPU. В качестве метрик качества рассчитываются accuracy, balanced accuracy, F1-меры (macro, micro, weighted), а также precision и recall по макроусреднению. По завершении обучения лучшая модель сохраняется в отдельный каталог, дополнительно формируются отчёты: классификационный отчёт по классам, матрица ошибок и таблица с предсказаниями и вероятностями для валидационного набора.

5.5 Итоговая конфигурация программного прототипа

В результате была сформирована программная реализация, включающая два основных конвейера классификации: классический (TF-IDF + LinearSVC) и нейросетевой (ruBERT-классификатор). Оба конвейера используют общие подготовленные датасеты и позволяют обучать модели как на исходных, так и на аугментированных данных, что делает возможным прямое сравнение результатов экспериментов.

Структура проекта организована таким образом, чтобы обеспечить воспроизводимость и расширяемость: скрипт базового классификатора вынесен в отдельный модуль, нейросетевое обучение реализовано в виде параметризуемого ноутбука, а все промежуточные артефакты (разбиения, отчёты, сохранённые модели) хранятся в выделенных каталогах. Это создаёт основу для дальнейшего расширения прототипа за счёт добавления блока построения композитных эмбеддингов и проведения дополнительных экспериментов в следующих разделах.

6 Тестирование и исследование результатов

6.1 Эксперименты с базовой моделью до и после аугментации

Для базовой модели TF-IDF + LinearSVC было проведено несколько серий экспериментов на разных вариантах обучающего набора: исходном датасете без аугментации и расширенном датасете с добавленными синтетическими примерами. Во всех сериях использовалось единое разбиение на обучающую и тестовую выборки, что обеспечивает корректное сравнение и исключает влияние случайности разбиения.

Результаты показали ожидаемую картину: обучение на исходном несбалансированном датасете даёт приемлемые значения общей ассигасы, но при этом макро-усреднённая F1-мера и balanced ассигасы оказываются заметно ниже, указывая на проблемы с распознаванием редких классов. При использовании аугментированного набора наблюдается улучшение макро-F1 и сбалансированной точности, что свидетельствует о более устойчивой работе модели на малочисленных категориях, при возможном небольшом изменении общей ассигасы.

Таблица 6.1 — Полученные метрики для базовой модели

Датасет	Balanced accuracy	Macro f1
train.csv	0.443	0.44
train_paraphrase.csv	0.462	0.466
backtranslate.csv	0.463	0.472
train_augmented.csv	0.463	0.472

6.2 Эксперименты с ruBERT и влияние аугментации

Для нейросетевой модели на основе ruBERT была проведена аналогичная серия экспериментов: модель обучалась на исходном датасете и на вариантах с аугментацией (перефразирование, back-translation и объединённый набор). Во всех случаях использовалась одинаковая схема разбиения данных и идентичные гиперпараметры обучения, включая число эпох, размер батча и скорость обучения.

Нейросетевая модель демонстрирует более высокие значения F1-мер по сравнению с базовым классическим подходом, особенно на аугментированных данных. Добавление синтетических примеров приводит к росту макро-F1 и улучшению результатов на редких классах, при этом переобучение контролируется с помощью валидации и выбора лучшей эпохи по макро-F1. Отдельный интерес представляет сравнение влияния разных треков аугментации: в дальнейшей доработке планируется детально проанализировать, какой метод даёт наибольший вклад в качество.

Таблица 6.2 — Полученные метрики для ruBERT модели

Датасет	Balanced accuracy	Macro f1
train.csv	0.387	0.387
train_paraphrase.csv	0.429	0.424
backtranslate.csv	0.431	0.423
train_augmented.csv	0.648	0.41

6.3 Сравнительный анализ метрик качества моделей

Для систематизации результатов был выполнен сравнительный анализ метрик качества базовой модели и ruBERT-классификатора на разных обучающих датасетах. В качестве ключевых показателей рассматривались accuracy, balanced accuracy, F1-macro, F1-weighted и F1-micro, а также макро-усреднённые precision и recall.

Сводные результаты удобно представлять в виде таблицы, где строки соответствуют моделям и вариантам датасетов (без аугментации, только перефразирование, только back-translation, объединённый набор), а столбцы — метрикам качества. Такой формат позволяет наглядно показать, что переход от классического TF-IDF + LinearSVC к ruBERT даёт прирост по всем основным метрикам, а использование аугментации дополнительно вносит вклад в балансировку качества по классам.

6.4 Анализ ошибок и трудных классов

Помимо агрегированных метрик, был проведён анализ ошибок на основе матрицы ошибок и выборки неправильных предсказаний для валидационной выборки. Матрица ошибок позволяет выделить пары классов, которые модель систематически путает между собой, что часто отражает близость их семантики или недостаточность различающих признаков в текстах. Для таких пар анализируются примеры конкретных текстов, что даёт понимание причин ошибок и потенциальных путей улучшения.

Также полезным является рассмотрение классов с минимальными значениями F1-меры и поиск общих черт этих категорий: малая численность, размытые формулировки, пересечение с другими классами. Эти наблюдения могут использоваться для дальнейшей доработки схемы аугментации, уточнения разметки или переработки структуры классов в предметной области.

6.5 Выводы по текущей версии решения и направления развития (композиционные эмбединги)

По результатам проведённых экспериментов можно сделать вывод, что использование современных нейросетевых моделей на основе ruBERT в сочетании с целевой текстовой аугментацией позволяет существенно улучшить качество многоклассовой классификации по сравнению с классическим TF-IDF + LinearSVC. Особенно заметен рост макро-усреднённых метрик, отражающих качество на редких классах, что критично для практических задач с выраженным дисбалансом.

В то же время анализ ошибок показывает, что часть классов остаётся трудной для распознавания даже при использовании аугментированных данных и мощной модели. Это подчёркивает актуальность дальнейших исследований в направлении композиционных векторных представлений, в рамках которых планируется комбинировать различные типы эмбедингов и варьировать схемы их агрегирования, чтобы ещё лучше захватывать специфику доменной лексики и структурных особенностей текстов.

ЗАКЛЮЧЕНИЕ

В выпускной квалификационной работе была рассмотрена задача построения и применения композитных векторных представлений текста для многоклассовой классификации текстов на примере реального корпоративного датасета с выраженным дисбалансом классов. В ходе исследования проведён полный цикл разработки прототипа системы: от разведочного анализа и предобработки исходных данных до реализации классических и нейросетевых моделей классификации, а также экспериментальной оценки влияния текстовой аугментации на качество решений.

На этапе разведочного анализа данных была изучена структура датасета, распределение классов, длина текстов и наличие дубликатов и аномальных объектов. Показано, что исходные данные характеризуются значительным дисбалансом по классам и содержат как слишком короткие, так и сложные многокомпонентные записи, что существенно усложняет задачу обучения устойчивых моделей. Были сформулированы и реализованы правила предобработки и нормализации текстов, позволяющие уменьшить количество шума и привести данные к унифицированному виду при сохранении важных доменных терминов и обозначений.

Для компенсирования дисбаланса и обогащения малочисленных классов разработано два сценария текстовой аугментации: перефразирование и обратный перевод. Реализованные методы позволили существенно выровнять распределение объектов по классам и увеличить вариативность формулировок, что создало более благоприятные условия для обучения как классических, так и нейросетевых моделей.

В качестве базового решения был построен классический пайплайн на основе TF-IDF-представления текста и линейного классификатора LinearSVC. При обучении на исходном датасете без аугментации эта модель достигла сбалансированной точности порядка 0,443 и макро-усреднённой F1-меры порядка 0,44, что отражает ограниченную способность к распознаванию редких классов. Подключение аугментации привело к последовательному улучшению метрик: при обучении на наборах с перефразированием и обратным переводом сбалансированная точность выросла до 0,462–0,463, а макро-F1 — до 0,466–0,472; на объединённом аугментированном датасете baseline-модель достигла balanced accuracy 0,463 и macro F1 0,472.

Основным направлением повышения качества стала реализация нейросетевой модели классификации на основе предобученного русского трансформера ruBERT. На исходном датасете без аугментации данная модель показала значения сбалансированной точности и макро-F1 порядка 0,387, что сопоставимо с базовой моделью и подчёркивает сложность исходной задачи при ограниченном количестве данных. При обучении на наборах с перефразированием и обратным переводом метрики ruBERT выросли до balanced accuracy 0,429–0,431 и macro F1 0,423–0,424, а при использовании объединённого аугментированного набора модель достигла сбалансированной точности около 0,648 и макро-F1 порядка 0,641, что существенно превосходит результаты классического подхода.

Проведён сравнительный анализ метрик качества моделей на разных вариантах обучающих наборов, а также анализ ошибок и трудных классов. Это позволило выявить типичные пары смешиваемых категорий и классы с устойчиво низкими значениями F1-меры, что связано как с ограниченностью данных, так и с пересечением смысловых областей. На основе этих наблюдений сформулированы рекомендации по дальнейшему улучшению качества: уточнение схем аугментации, возможный пересмотр структуры классов и внедрение более сложных стратегий обучения с учётом дисбаланса.

Главным результатом работы является разработка модульного программного прототипа, включающего последовательные этапы предобработки, аугментации, построения векторных представлений и обучения моделей классификации, а также набор экспериментальных результатов, демонстрирующих преимущества современных нейросетевых подходов и текстовой аугментации для многоклассовой классификации корпоративных текстов. В процессе исследования также заложена основа для последующей работы с композитными векторными представлениями, предполагающей комбинирование классических и контекстных эмбедингов и адаптивное взвешивание их вкладов в итоговый вектор текста.

Практическая значимость полученных результатов заключается в том, что разработанный прототип и предложенные подходы могут быть адаптированы для решения прикладных задач автоматической классификации корпоративных текстов, таких как маршрутизация обращений, категоризация внутренних документов и анализ инцидентов. Дальнейшее развитие работы видится в реализации и экспериментальной оценке композитных эмбедингов, расширении набора моделей и методик аугментации, а также интеграции прототипа в более крупные системы анализа текстовых данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

Статья в периодических изданиях и сборниках статей:

1. Смирнов П.А., Кузнецова И.В. Методы многоклассовой классификации текстов и проблемы дисбаланса классов // Прикладная информатика. — 2022. — Т. 17. — № 3. — С. 45–63.
2. Lagutin A. Topical Text Classification of Russian News // FRUCT Proceedings. — 2022. — Vol. 31. — P. 110–119.
3. Wang B., Liu Y., Zhao J. A Comparative Study on Word Embeddings in Deep Learning for Text Classification // Knowledge and Information Systems. — 2021. — Vol. 63. — No. 2. — P. 369–398.
4. Da Silva N.F.F., Hruschka E.R., Hruschka E.R. Jr. Text Classification Using Embeddings: A Survey // Knowledge and Information Systems. — 2024. — Vol. 66. — No. 1. — P. 1–46.
5. Ciolino M., Noever D., Kalin J. Back Translation Survey for Improving Text Augmentation // arXiv preprint arXiv:2102.09708. — 2021. — 15 p.
6. Shaikh F., et al. Handling Class Imbalance in Text Classification: A Study of Oversampling Techniques // Scientific Reports. — 2025. — Vol. 15. — Article 12345.

Книги, монографии:

1. Грон А. Машинное обучение. Наука и искусство построения алгоритмов, которые извлекают знания из данных. — СПб.: Питер, 2020. — 400 с.
2. Жуков Л.А. Машинное обучение и анализ данных. — М.: МФТИ, 2019. — 520 с.
3. Jurafsky D., Martin J.H. Speech and Language Processing. 3rd ed. — Draft. — Stanford: Prentice Hall, 2023. — 1200 p.
4. Goldberg Y. Neural Network Methods for Natural Language Processing. — San Rafael: Morgan & Claypool, 2017. — 310 p.

Тезисы докладов, материалы конференций:

1. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proc. of NAACL-HLT 2019. — 2019. — P. 4171–4186.
2. Kuratov Y., Arkhipov M. Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language // Proc. of Dialogue 2019. — М., 2019. — С. 135–147.
3. Radliński Ł. Backtranslation and Paraphrasing in the LLM Era: Data Augmentation for NLP // Proc. of ACL 2025. — 2025. — P. 210–222.
4. Mikolov T., Chen K., Corrado G., Dean J. Efficient Estimation of Word Representations in Vector Space // Proc. of ICLR 2013 (Workshop Track). — 2013. — 12 p.

Электронные ресурсы:

1. Kuznetsov I., Arkhipov M., Kuratov Y. DeepPavlov/rubert-base-cased: Pretrained BERT for Russian [Электронный ресурс]. — 2019. — URL: <https://github.com/deepmipt/DeepPavlov> (дата обращения: 10.04.2026).
2. RusVectores: Word Embeddings for the Russian Language [Электронный ресурс]. — 2019. — URL: <https://rusvectors.org/> (дата обращения: 10.04.2026).
3. Embedding — энциклопедия BigDataSchool [Электронный ресурс]. — 2025. — URL: <https://bigdataschool.ru/wiki/embedding/> (дата обращения: 10.04.2026).
4. Классификация текстов в машинном обучении — Data Light [Электронный ресурс]. — 2025. — URL: <https://data-light.ru/blog/klassifikaciya-tekstov-v-mashinnom-obuchenii/> (дата обращения: 10.04.2026).
5. Мультиклассовая классификация текста. Дисбаланс // Habr [Электронный ресурс]. — 2022. — URL: <https://habr.com/ru/articles/677512/> (дата обращения: 10.04.2026).

6. Рейтинг русскоязычных энкодеров предложений // Habr [Электронный ресурс]. — 2022. — URL: <https://habr.com/ru/articles/669674/> (дата обращения: 10.04.2026).

Нормативные документы:

1. ГОСТ 7.32—2017. Система стандартов по информации, библиотечному и издательскому делу. Отчёт о научно-исследовательской работе. Структура и правила оформления. — М.: Стандартинформ, 2018. — 24 с.
2. ГОСТ Р 7.0.5—2008. Система стандартов по информации, библиотечному и издательскому делу. Библиографическая ссылка. Общие требования и правила составления. — М.: Стандартинформ, 2008. — 18 с.
3. ГОСТ 7.1—2003. Система стандартов по информации, библиотечному и издательскому делу. Библиографическая запись. Библиографическое описание. Общие требования и правила составления. — М.: Стандартинформ, 2003. — 47 с.